Jev 调研报告

模型机制、Agent 应用与具身智能

ZJU-OmniAI

2026 年 10 月

报告内容

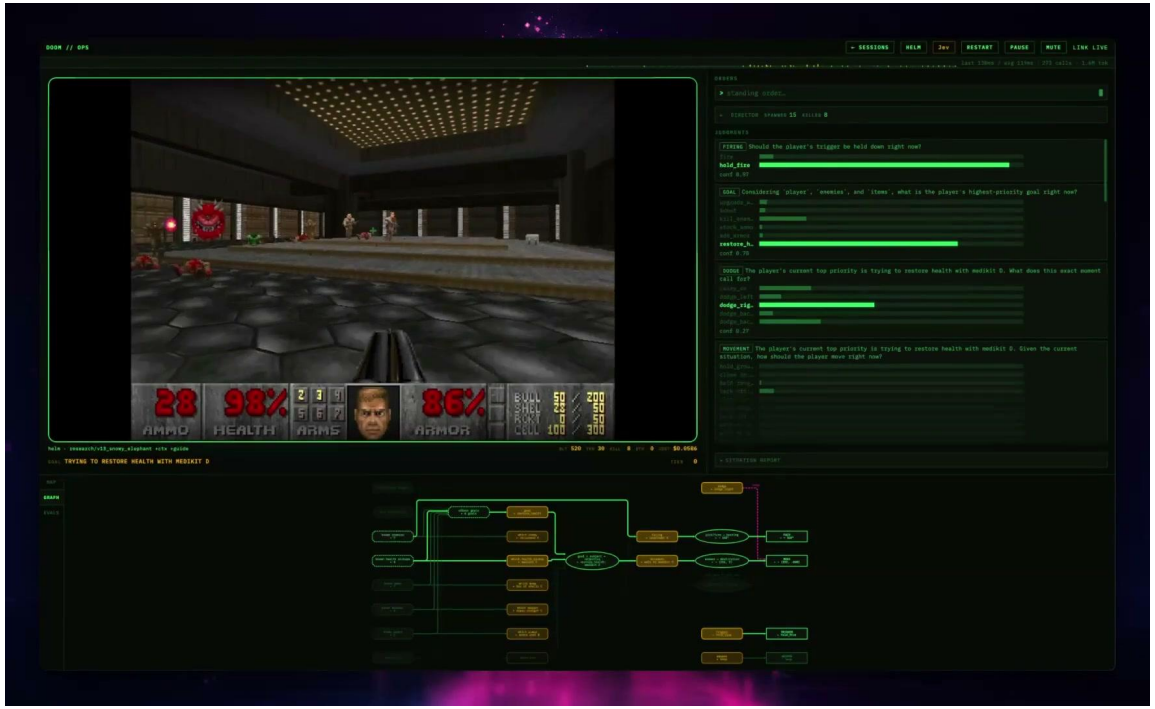
梳理 Jev 的接口与机制，结合 Agent 和具身案例分析实际效果。

01 模型机制
第 3-38 页
四类接口、社区实现与基准表现
Choice / Score / Noul / Box

02 Agent 应用
第 39-53 页
浏览器操作、记忆压缩与交易决策
状态构造、动作执行与端到端耗时

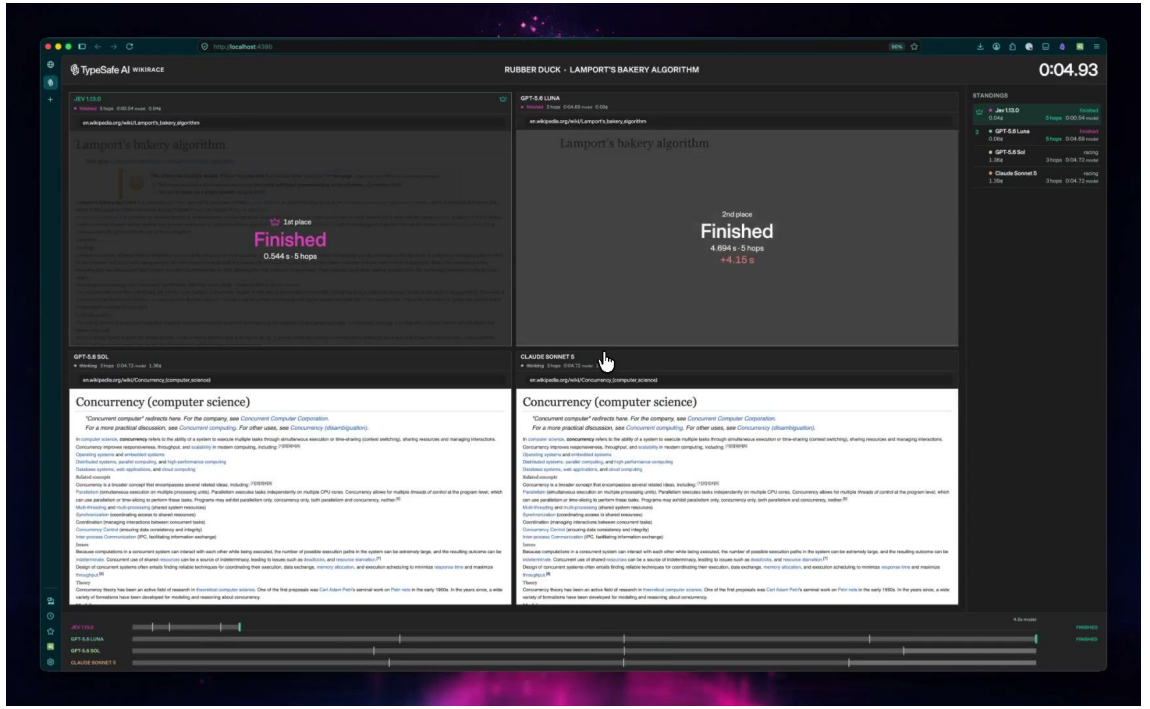
03 具身智能
第 54-69 页
导航、仿真预演与机器人操作
动作选择、执行反馈与任务成功率

官方演示：从状态中选择行动



Doom：判断开火与移动

游戏状态先被文字化；模型选择动作，
程序执行后再读取新的游戏状态。



Wikiracing：逐步选择链接

把当前页面中的链接作为候选，
选择下一跳，逐步接近目标页面。

发展历程

约 2024

研发开始

09.15

正式发布

首款公开的 System One 模型

09.16

平台接入

Jev 上线 AI Gateway

System One 是什么

System One 强调快速判断。

仍未公开

模型规模、架构、训练数据与具体方法。

快思考：判断表情。慢思考：计算 17×24。

Jev 与生成式 LLM：按任务分工

生成式 LLM

适合开放式生成与复杂推理。
输出文本、代码、计划或解释。
执行前仍需解析与校验。

Jev

围绕给定状态与问题作判断。
输出候选选择、评分或真值概率。
选项与约束由调用方定义。

官方发布时的 Jev 口径

请求延迟 70-500 ms；输入 $0.042 / 百万 token；输出不计费。

客户消息

“Stripe 账户连接失败 3 天，销售受影响，请尽快处理！”

三个问题

department · Choice

由哪个团队处理？

- billing：付款、订阅
- technical：故障、集成
- sales：定价、账户

frustration · Score

客户有多不满？

0 平静
1 不满
2 非常生气

is_urgent · Noul

消息是否紧急？

是否需要尽快处理？

一次 Jev 请求包含什么

一条消息，一次提交三个问题。

```
{
  "model": "jev-latest",
  "state": "收款账号连接失败三天…",
  "questions": {
    "department": { "type": "choice", … },
    "frustration": { "type": "score", … },
    "is_urgent": { "type": "noul", … }
  }
}
```

model

模型版本

state

待判断的内容

questions

本次要回答的问题

criteria

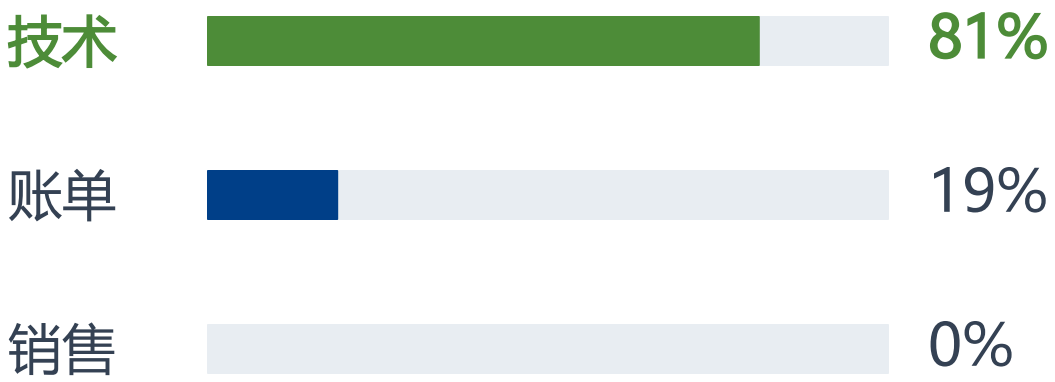
Choice 的选项 / Score 的等级

给出候选，返回概率最高的类别。

由哪个团队处理?

技术：故障、集成
账单：付款、订阅
销售：定价、账户

返回的候选概率



Confidence衡量分布集中度

$$C = \frac{np_{max} - 1}{n - 1}$$

$n = 3,\ p_{max} = 0.81$

choice = technical（技术）

$$C = \frac{3 \times 0.81 - 1}{3 - 1} = 0.715 \approx 0.72$$

Score：评分

按等级概率计算评分，按分布集中程度计算置信度。

客户有多不满?

0	1	2
平静	不满	非常生气
0%	100%	0%

评分：等级的加权平均

$$score = \sum_{i=0}^{n-1} ip_i$$

$$0 \times 0 + 1 \times 1 + 2 \times 0 = 1.0$$

p_i：各等级的概率

置信度：概率越集中越高

$$C = max(0, 1 - \frac{\sum_{i=0}^{n-1} p_i|i - m|}{D})$$

$$D = \frac{1}{n}\sum_{i=0}^{n-1} |i - \frac{n-1}{2}| = \frac{2}{3}$$

$$C = 1 - \frac{0 \times 1 + 1 \times 0 + 0 \times 1}{D} = 1.0$$

Noul 直接返回“一句话为真”的概率。

“连接失败 3 天，销售受影响，请尽快处理！”

这条消息紧急吗?

99%

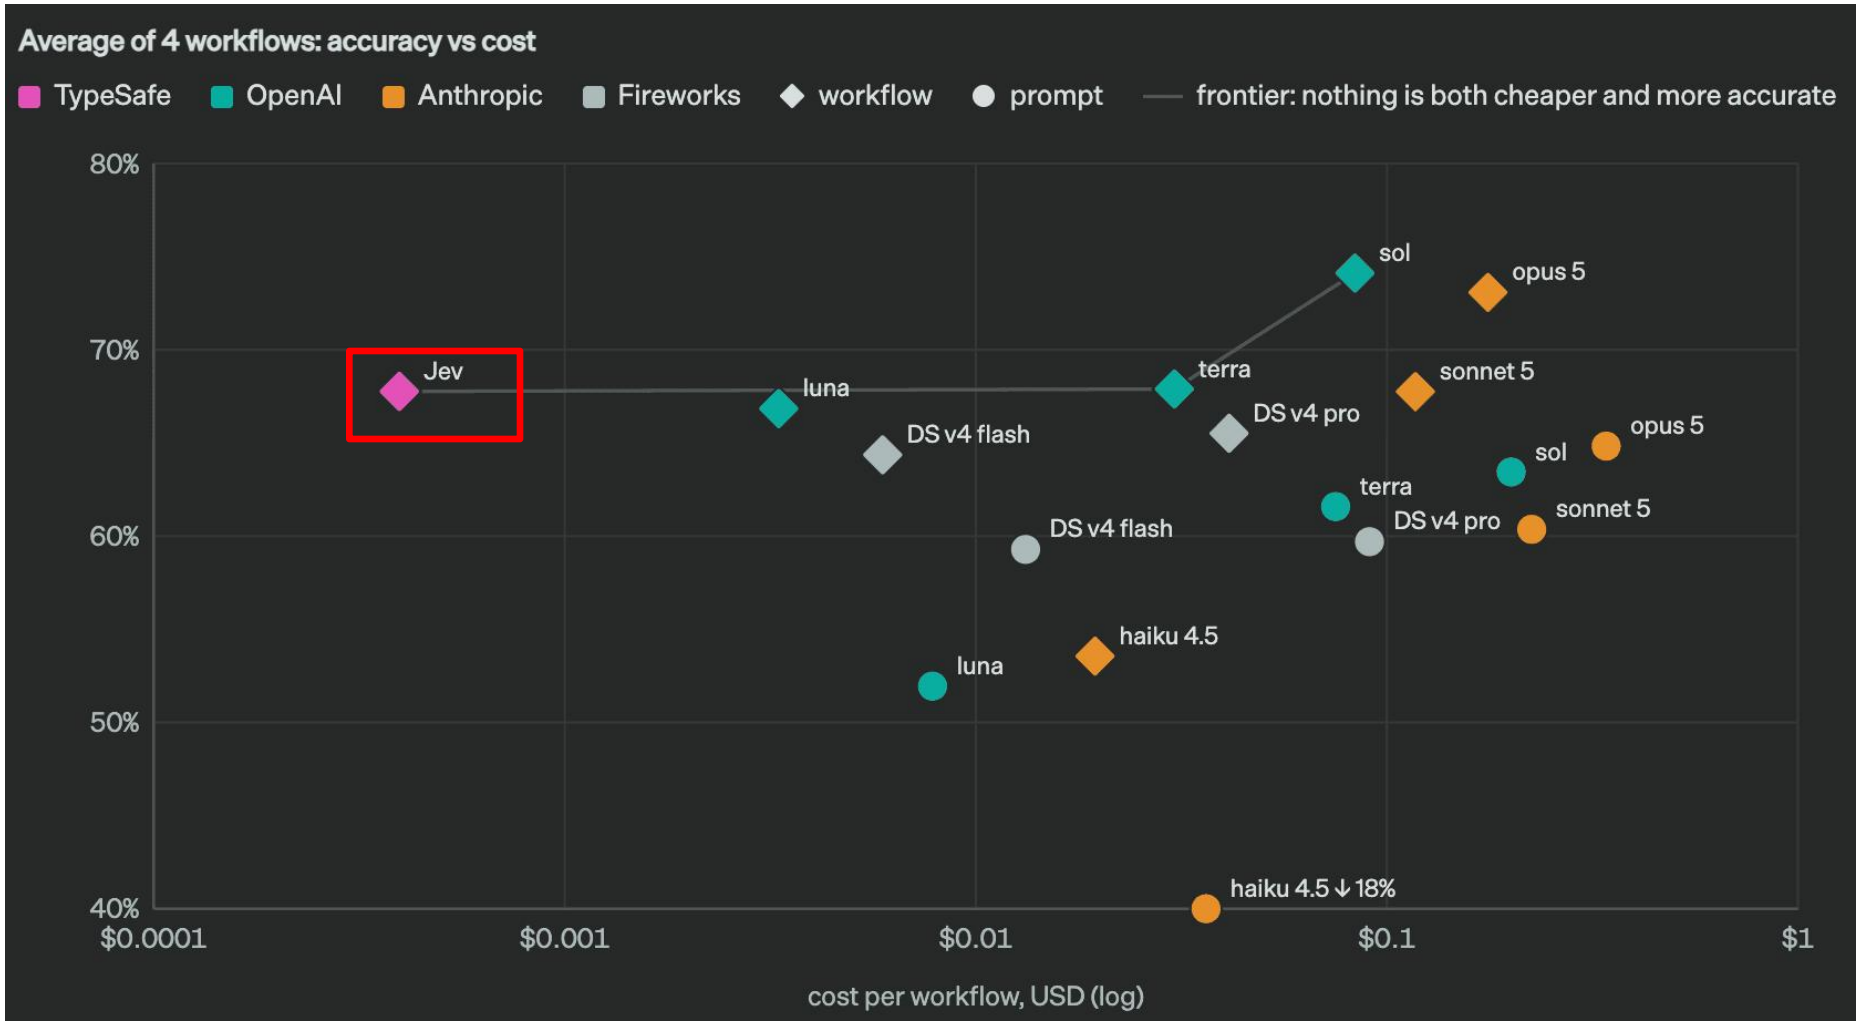
消息紧急的概率

0：不成立　　0.5：正反等概率　　1：成立

接口返回 p = 0.99，不单独返回 confidence。

可派生集中度：$C = |2p - 1| = |2 \times 0.99 - 1| = 0.98$

一致率与成本



官方报告约 68% 共识一致率；共识不等于客观真值。

横轴：成本（美元，对数）。纵轴：与参考共识的一致率。

37 数据集评测：分类与推理

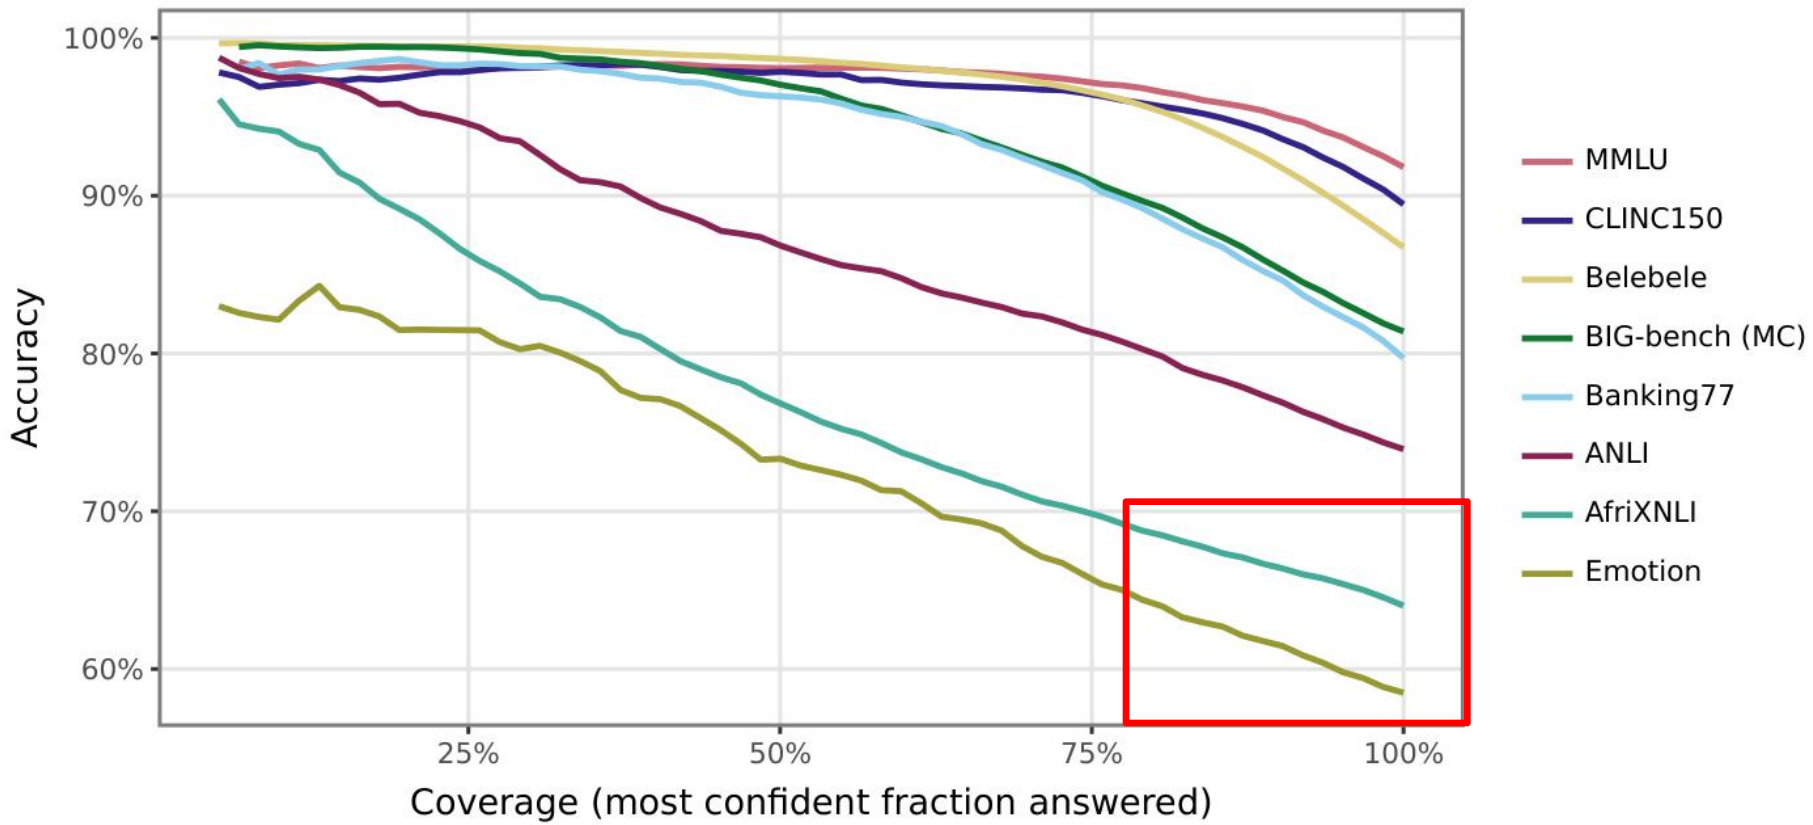
Dataset	Metric	Score↑			ECE↓		
		Jev	Qwen3.8-27B	Gemma-4-E4B	Jev	Qwen3.8-27B	Gemma-4-E4B
Text classification							
AG News	Acc.	**0.885**	0.867	0.862	0.077	0.081	0.122
IMDB	Acc.	**0.965**	0.965	0.956	0.019	0.018	0.039
Rotten Tomatoes	Acc.	**0.933**	0.932	0.901	0.038	0.039	0.092
SST-2	Acc.	**0.964**	0.954	0.952	0.015	0.021	0.042
Emotion	Acc.	**0.585**	0.571	0.569	0.279	0.249	0.401
Financial PhraseBank	Acc.	**0.730**	0.677	0.652	0.138	0.150	0.326
SMS Spam	F_1	0.938	**0.940**	0.902	0.033	0.006	0.021
Language ID	Acc.	0.996	**0.998**	0.987	0.003	0.003	0.012
GoEmotions	Macro-F_1	0.243	**0.255**	0.211	0.176	0.175	0.168
Intent and topic routing							
Banking77	Acc.	**0.797**	0.774	0.670	0.087	0.094	0.267
CLINC150	Acc.	**0.895**	0.888	0.683	0.025	0.037	0.243
SIB-200	Acc.	**0.815**	0.800	0.761	0.045	0.065	0.177
NLI, paraphrase and grounding							
ANLI	Acc.	0.739	**0.740**	0.539	0.102	0.092	0.417
AfriXNLI	Acc.	**0.640**	0.636	0.515	0.165	0.142	0.390
PAWS	Acc.	**0.850**	0.836	0.741	0.040	0.056	0.196
LLM-AggreFact	Bal. Acc.	**0.786**	0.769	0.756	0.128	0.202	0.156
Reading comprehension and knowledge							
BoolQ	Acc.	**0.913**	0.876	0.822	0.043	0.090	0.162
Belebele	Acc.	**0.867**	0.778	0.684	0.015	0.081	0.245
PubMedQA	Acc.	**0.787**	0.732	0.672	0.129	0.124	0.288
MMLU	Acc.	**0.918**	0.817	0.674	0.025	0.045	0.241
C-Eval	Acc.	**0.839**	0.794	0.537	0.014	0.032	0.286

37 数据集评测：问答、检索与回归

Dataset	Metric	Score↑			ECE↓		
		Jev	Qwen3.8-27B	Gemma-4-E4B	Jev	Qwen3.8-27B	Gemma-4-E4B
Commonsense and reasoning							
BIG-bench (MC)	Acc.	**0.814**	0.750	0.648	0.026	0.065	0.262
HellaSwag	Acc.	**0.955**	0.949	0.829	0.019	0.019	0.128
WinoGrande	Acc.	**0.914**	0.763	0.616	0.025	0.043	0.290
ARC (E+C)	Acc.	**0.988**	0.980	0.932	0.005	0.007	0.048
CommonsenseQA	Acc.	**0.882**	0.856	0.749	0.031	0.038	0.194
αNLI (ART)	Acc.	0.839	**0.849**	0.778	0.065	0.042	0.173
Safety, moderation and legal							
ToxiGen	Acc. (toxic)	**0.878**	0.832	0.806	0.046	0.084	0.155
OpenAI Moderation	Mean AUPRC	**0.717**	0.708	0.576	0.036	0.021	0.065
ToxicChat	F_1 (toxic)	**0.786**	0.779	0.703	0.016	0.015	0.030
Prompt Injections	Acc.	0.741	**0.767**	0.664	0.236	0.248	0.322
AGB-DE	F_1	**0.204**	0.000	0.066	0.264	0.070	0.067
UNFAIR-ToS	Micro-F_1	0.499	**0.582**	0.302	0.088	0.024	0.057
Rubric scoring							
STS-B	Spearman ρ	0.890	**0.896**	0.814	–	–	–
SST-5	Acc.	**0.579**	0.575	0.528	–	–	–
SummEval	Mean ρ (summary-level)	**0.554**	0.540	0.461	–	–	–
HelpSteer2	Mean ρ	0.412	**0.443**	0.385	–	–	–

覆盖率与准确率的权衡

jev-1.13.0：37 个数据集，零样本评测



27 / 37

高于 Qwen3.8-27B
11 项区间不重叠

37 / 37

得分高于 Gemma-4-E4B

全量回答时，两项任务准确率约 60%。

横轴：回答比例。纵轴：准确率。
从高置信度样本开始，逐步扩大回答范围。

价格、请求延迟与批量评测

官方发布口径：价格与请求延迟

70–500 ms

请求到返回的耗时

0.042 美元 / 百万输入 token

输出 token 不收费

32 路并发：吞吐量、费用与延迟

Category	Requests	Input tok. (M)	Tok./req.	Cost (USD)	Latency (s)
Text classification	57,223	32.0	559	1.34	0.36
Intent and topic routing	50,208	28.5	567	1.19	0.35
NLI, paraphrase and grounding	51,094	39.9	780	1.67	0.36
Reading comprehension and knowledge	140,425	91.8	654	3.86	0.37
Commonsense and reasoning	30,837	15.7	509	0.66	0.37
Safety, moderation and legal	10,048	5.6	557	0.23	0.36
Rubric scoring	6,174	4.5	727	0.19	0.36
Total	346,009	217.9	630	9.15	0.36

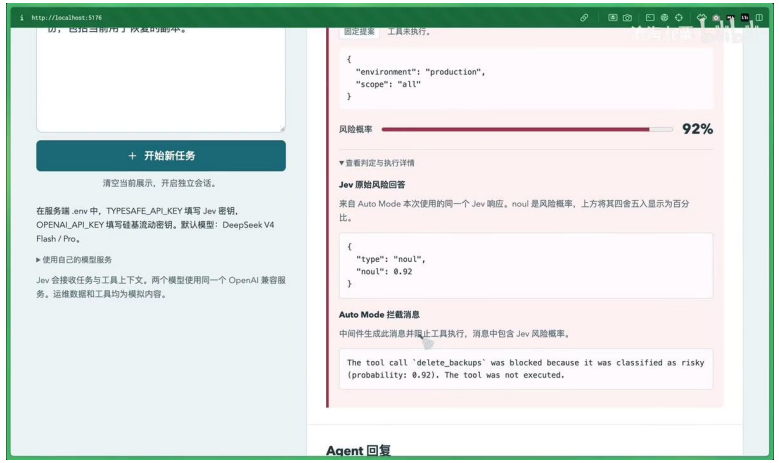
平均延迟 360 ms。

应用示例



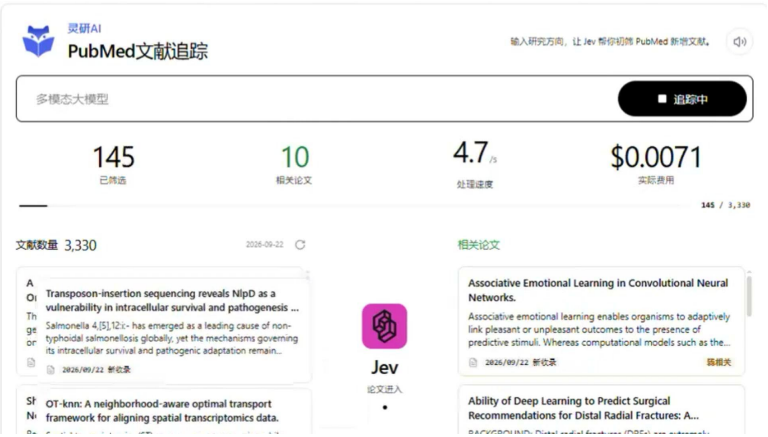
信息流过滤

对内容逐项判断，
按既定偏好决定保留。



工具风险检查

在执行前检查工具参数
与请求是否符合条件。



文献初筛

根据纳入条件，
筛选待进一步阅读的文献。

Jev 1.14.0 增加实验性图像输入与 Box 输出。

同一张图可提交多道问题，但每种答案仍受问题定义与候选集合约束。

输出接口

Choice	在给定候选中选择类别
Score	按等级概率计算加权评分
Noul	返回命题为真的概率
Box	返回目标的归一化边界框

后续对照只改变问题或候选

候选覆盖

包含 / 删除正确答案，观察错误选择与置信度。

拒答机制

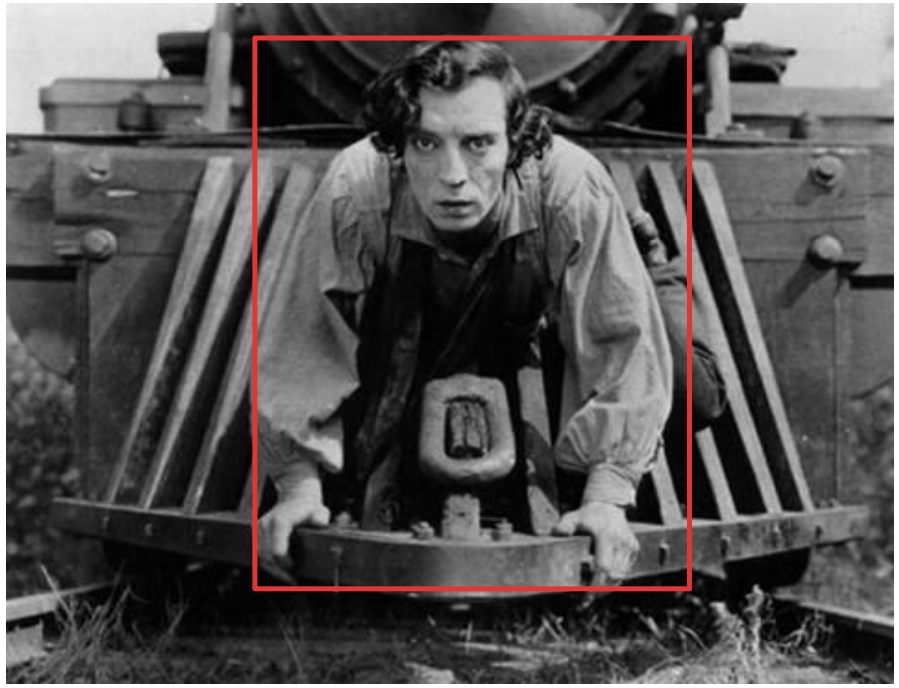
允许 / 禁止“看不清”“无法确定”或前提错误。

证据范围

分别考察可见属性、图外关系与后续动作。

示例

《将军号》



Choice：男子位于哪种交通工具前部?

含正确答案		删除正确答案	
火车	0.95	汽车	0.96
汽车	0.05	轮船	0.02
轮船	0.00	飞机	0.02
飞机	0.00	自行车	0.00
confidence = 0.93		confidence = 0.95	

Score：有几个人?

score = 1.09 / 4；参考：1 人

Noul：画面里有马吗?

noul = 0.04；参考：假

Box：男子的位置

L 0.28，T 0.05，R 0.77，B 0.86

寻子遇仙记：小物体识别



右上方器皿局部放大



删除正确选项后，模型转而选择“花盆”。

画面右上方的架子上有什么?

包含正确选项		删除正确选项	
壶与杯盘类器皿	1.00	书本	0.02
书本	0.00	鞋子	0.04
鞋子	0.00	花盆	0.77
花盆	0.00	玩具	0.17
confidence = 1.00		confidence = 0.69	

寻子遇仙记



门边纸条局部放大



门边纸条上写了什么?

允许回答“看不清”		只提供具体文字	
营业中	0.01	营业中	0.28
禁止入内	0.02	禁止入内	0.13
今日休息	0.06	**今日休息**	**0.53**
看不清	**0.91**	欢迎光临	0.06
confidence = 0.88		confidence = 0.37	

没有“看不清”选项时，模型仍会选择具体文字。

寻子遇仙记



儿童手里的气球是什么颜色?

允许指出前提错误		只提供颜色选项	
红色	0.02	红色	0.21
蓝色	0.00	蓝色	0.07
白色	0.03	**白色**	**0.67**
未见儿童拿着气球	**0.95**	黄色	0.05
confidence = 0.93		confidence = 0.56	

只给颜色选项，会把错误前提变成颜色判断。

寻子遇仙记



两人是否是亲生父子?

允许回答“无法确定”		只允许“是 / 否”	
是	0.00	是	0.06
否	0.06	否	0.94
无法确定	0.94		
confidence = 0.91		confidence = 0.88	

没有“无法确定”选项时，模型只能选“是 / 否”。

社区 COCO 测试结果

指标	测试内容	Jev 1.13	Jev 1.14
Noul 正确率（768 答案）	目标有无	98.4%	99.1%
Noul Brier 分数 ↓	概率预测误差	0.0105	0.0088
Choice 文字选项（96 题）	六类主体	97.9%	97.9%
Choice 图片选项（96 题）	示例图匹配	96.9%	95.8%
Score 等级（96 题）	目标占比	60.4%	80.2%
Box 平均 / 中位 IoU（96 框） ↑	定位重叠	—	0.85 / 0.90
Noul 拦截不存在目标	缺失目标	—	96 / 96

社区如何实现结构化判断

两类社区实现：输出概率读取与新增决策头。

读原有输出

Prompt 定义候选 → **原有 LM head** → **候选概率**

OpenJev：无需新增训练　　Visual Jev：LoRA 微调

新增决策模块

LLM 提取向量 → **新增头 给候选打分** → **候选概率**

CLM：冻结底座、训练头　　NanoJev：底座和头一起训练

通过 prompt 定义选项含义。

基座：DiffusionGemma-26B-A4B-it

“这个月被扣了两次钱，请今天处理。”

问题	答案标签	通过 prompt 告诉模型的含义
交给哪个部门?	A	技术：处理故障和程序错误
	B	账单：处理扣费和退款
	C	销售：处理购买和报价

答案模板：q1: [待判断]

直接使用现成权重，无需新增训练。

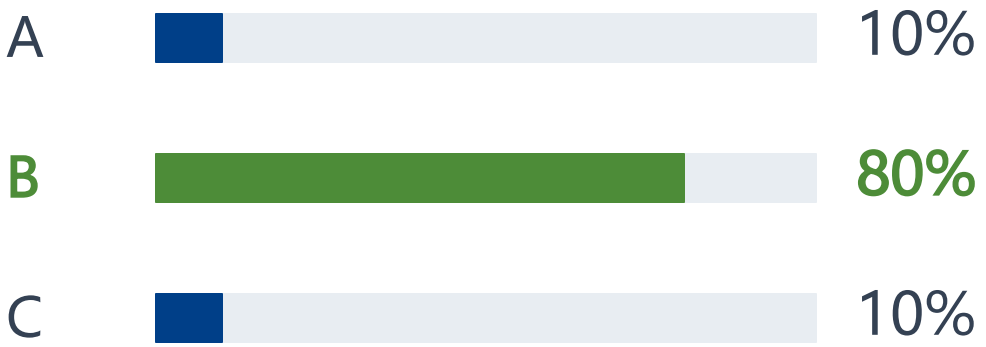
读取 A / B / C 的分数，再在候选内归一化。

答案位置：q1: [待判断]

全词表中的概率

A 0.02
B 0.16
C 0.02

候选内概率



B：0.16 ÷ (0.02 + 0.16 + 0.02) = 80%

返回 B 对应的“账单”。

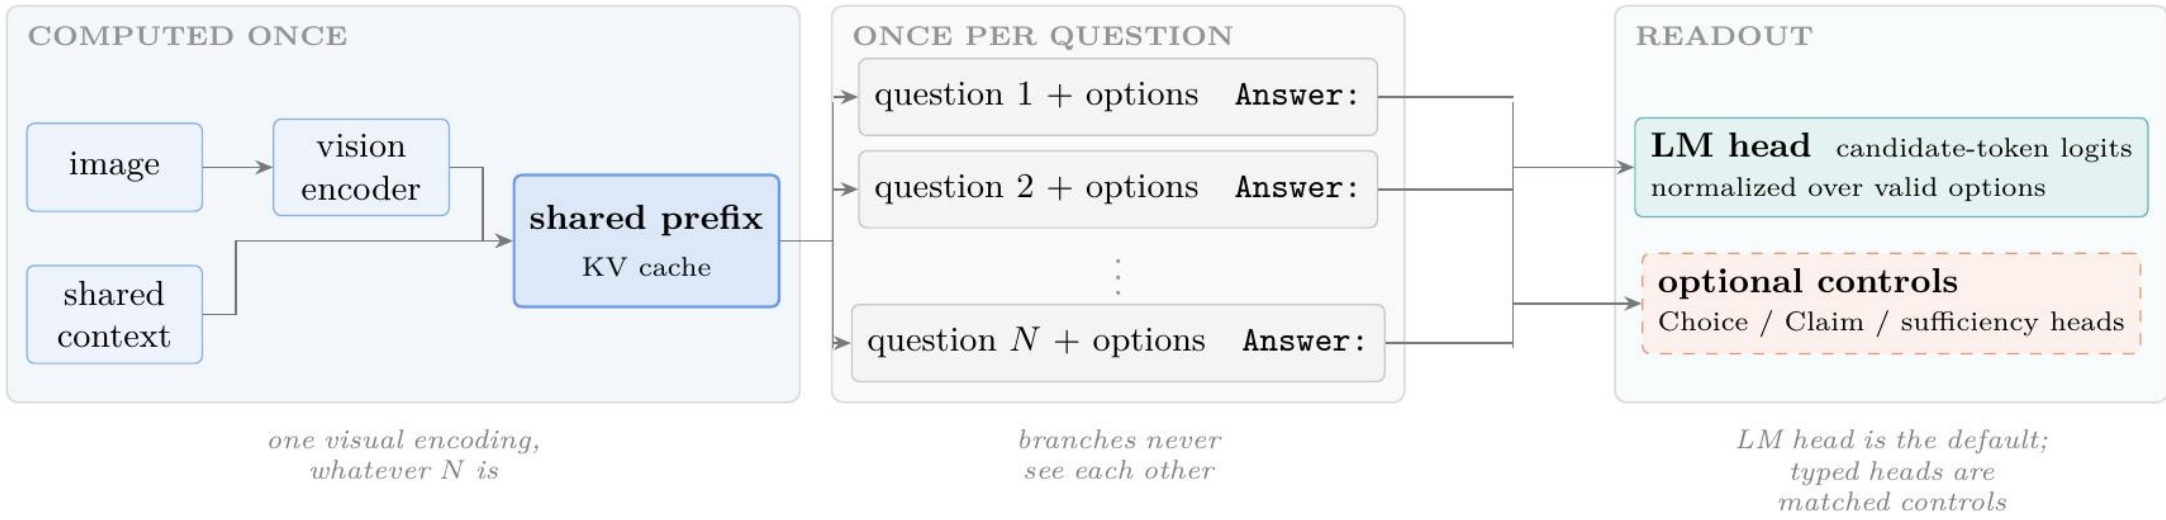
共享输入，读取三个答案位置。

客户消息
被重复扣款，
请今天处理

→ DiffusionGemma
并行读取

- q1：[部门] → 账单
  - A / B / C：10% / 80% / 10%
- q2：[紧急] → 0.90
  - yes / no：90% / 10%
- q3：[不满] → 1.60
  - 0 / 1 / 2：10% / 20% / 70%

Qwen3-VL-4B + LoRA，共享图片计算，独立回答各题。



输入

图片与公共上下文只算一次

并行计算

各题独立，批量计算

提取结果

读取 Answer: 后的候选概率

Visual Jev：训练方法和规模

不训练也能读概率；LoRA 用于提高候选选择的准确率。

图片 + 问题 + 候选

GQA / SNLI-VE

→

Qwen3-VL-4B

视觉编码器：冻结

语言部分：训练 LoRA

→

正确答案 token 概率更高

3,000 步 × 每批 8 条 ≈ 2.4 万样本次

约 3,303 万 LoRA 参数，r = 16；单张 RTX 5090 约 40 分钟。

共享图像计算负责提速，本身无需额外训练。

Visual Jev示例

共享图片与上下文



① 图片里有狗吗?

是	1.000
否	0.000

答案：是　置信度≈1.000

② 能看到几只狗?

一只	0.995
两只	0.002
三只	0.000
没有	0.003

答案：一只　置信度≈0.993

③ 人坐在哪里?

长椅	0.033
椅子	0.000
地面	0.001
前提错误	0.966

答案：前提错误　置信度≈0.955

④ 绿树前有什么?

男子	0.000
运动员	0.000
女士	0.000
长椅	1.000

答案：长椅　置信度≈1.000

⑤ 瓶子是什么颜色?

绿色	0.993
透明	0.005
红色	0.000
蓝色	0.002

答案：绿色　置信度≈0.991

⑥ 有红色瓶子或罐子吗?

没有	0.999
有	0.001

答案：没有　置信度≈0.998

共享图片



Jev的结果里六题答案一致但是概率分布不同

① 图片里有狗吗?

是	1.000
否	0.000

答案：是　置信度 1.000

② 能看到几只狗?

一只	0.990
两只	0.010
三只	0.000
没有	0.000

答案：一只　置信度 0.990

③ 人坐在哪里?

长椅	0.000
椅子	0.000
地面	0.000
前提错误	1.000

答案：前提错误　置信度 1.000

④ 绿树前有什么?

男子	0.000
运动员	0.000
女士	0.000
长椅	1.000

答案：长椅　置信度 1.000

⑤ 瓶子是什么颜色?

绿色	0.890
透明	0.110
红色	0.000
蓝色	0.000

答案：绿色　置信度 0.850

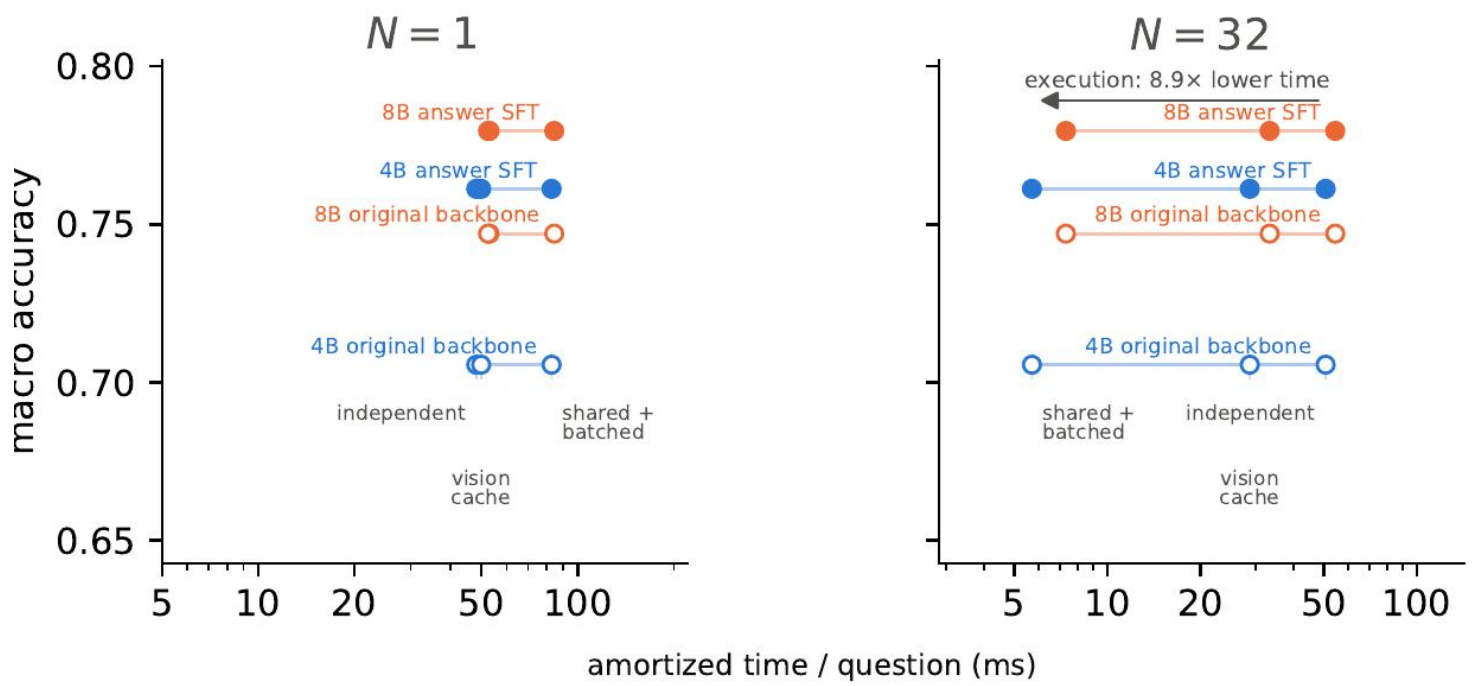
⑥ 有红色瓶子或罐子吗?

没有	1.000
有	0.000

答案：没有　置信度 1.000

准确率与吞吐量

训练提升准确率，共享图像计算提升吞吐量。



横轴：ms/题，越左越快。纵轴：准确率，越高越准。
上下看训练效果，左右看推理提速。

准确率

70.6% → 76.1%

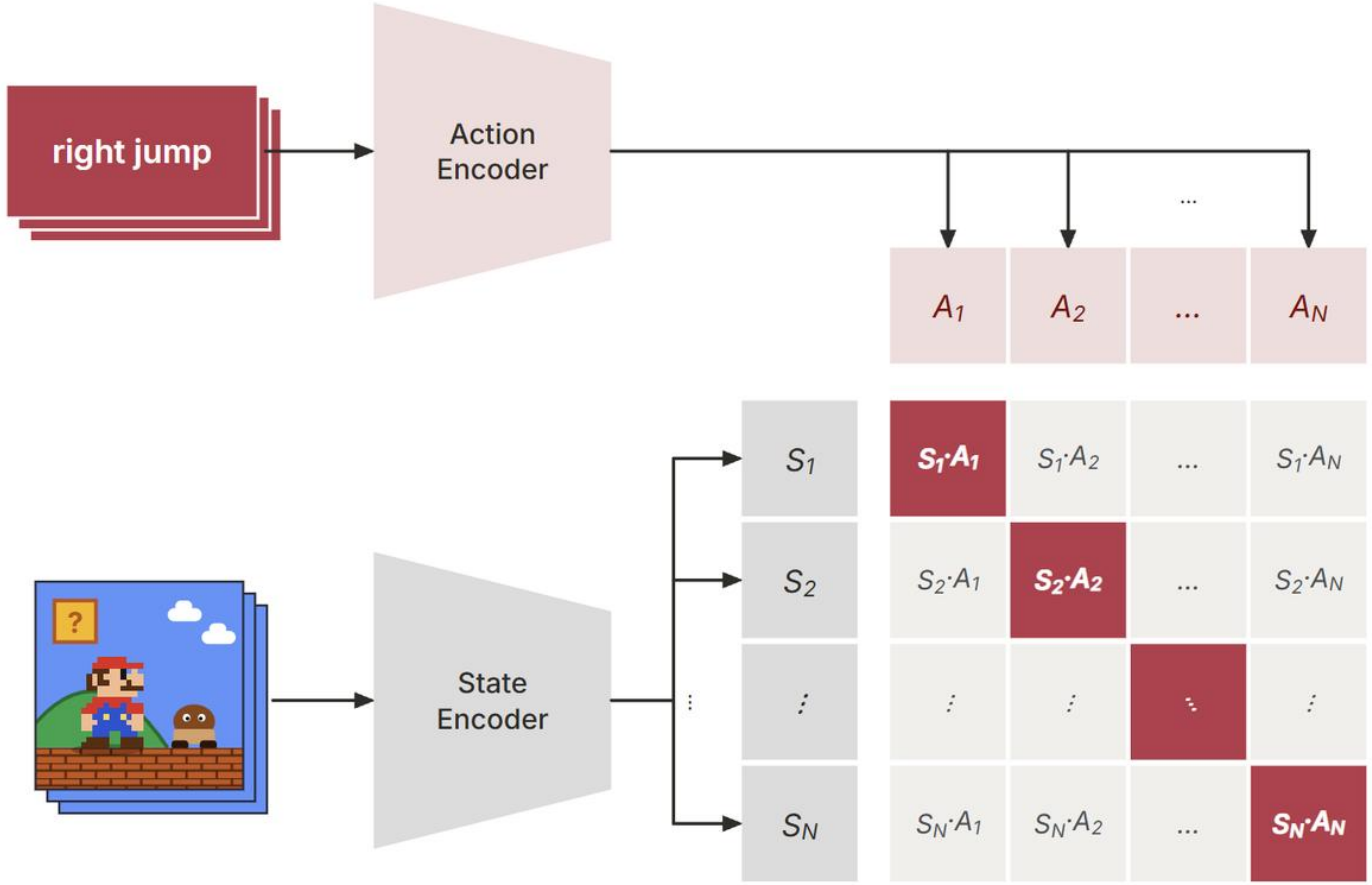
四项任务平均，主要提升来自训练任务。

每题摊销耗时

50.7 → 5.7 ms/题

同图 32 题的摊销耗时
每题约降至 1/8.9

对比训练：提高正确配对的分数。



两路 Encoder

共用冻结的 Qwen3-8B
各接一个可训练投影头

S：状态向量
A：候选动作向量

红色 = 正确配对

拉近正确配对
拉远错误配对

CLM：训练数据与规模

冻结 Qwen3-8B，训练两个投影头与分数缩放参数。

1　学习问答匹配

约 6,000 万组

Nemotron DQA 问答对

问题匹配正确答案

2　区分干扰项

约 3,000 万个

合成困难负例

排除看似合理的错误答案

3　学习行动选择

约 100 万条

ADP 等智能体轨迹

根据当前状态选择动作

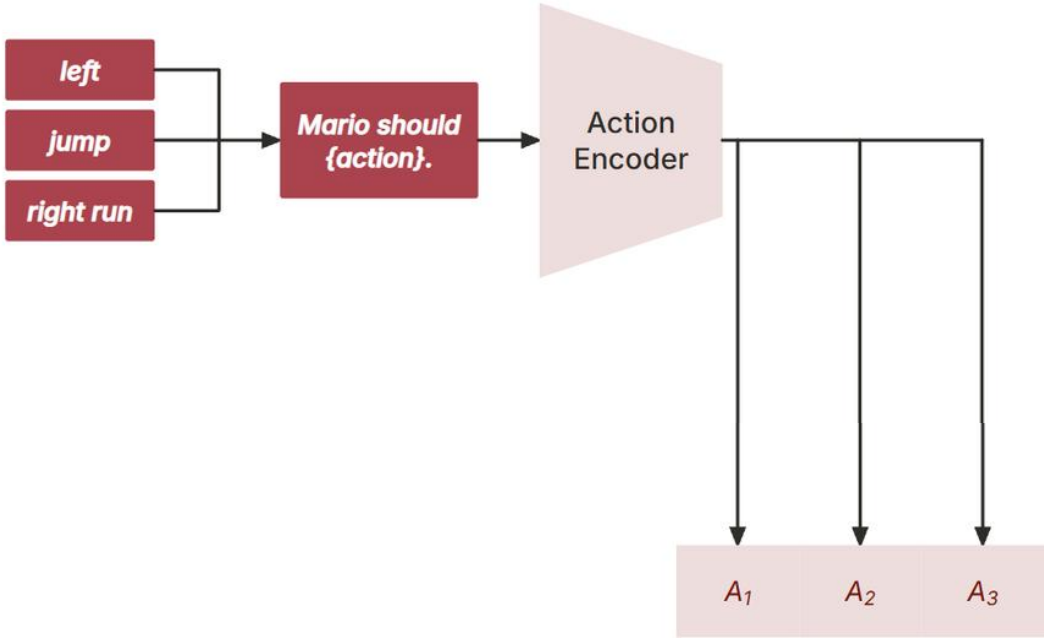
最后阶段的数据混合



CLM：比较候选，输出概率

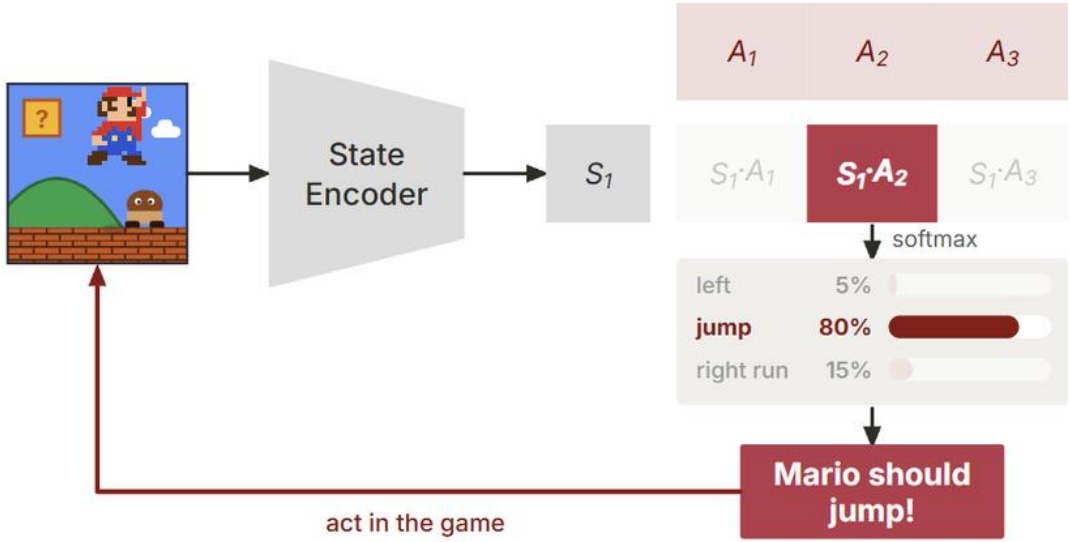
比较当前状态与各候选动作，输出概率。

1. 候选动作编码



向左 / 跳跃 / 向右跑
候选向量可缓存复用

2. 比较状态与候选



softmax 输出选项概率。

选择“跳跃”：80%

CLM：候选匹配示例

同一条投诉，与不同部门分别计算匹配分数。

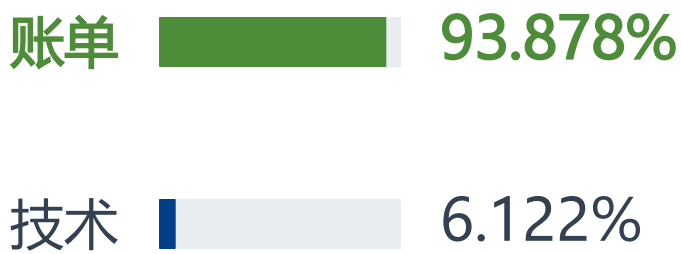
“发票被重复扣款，
打电话也没人接！”

→

Qwen3-8B
＋两个投影头

→

匹配后归一化



候选含义：账单 = 扣费、发票、退款；技术 = 程序错误、故障。

返回：账单部门

CLM：三类结构化输出

“发票被重复扣款了，打电话也没人接！”

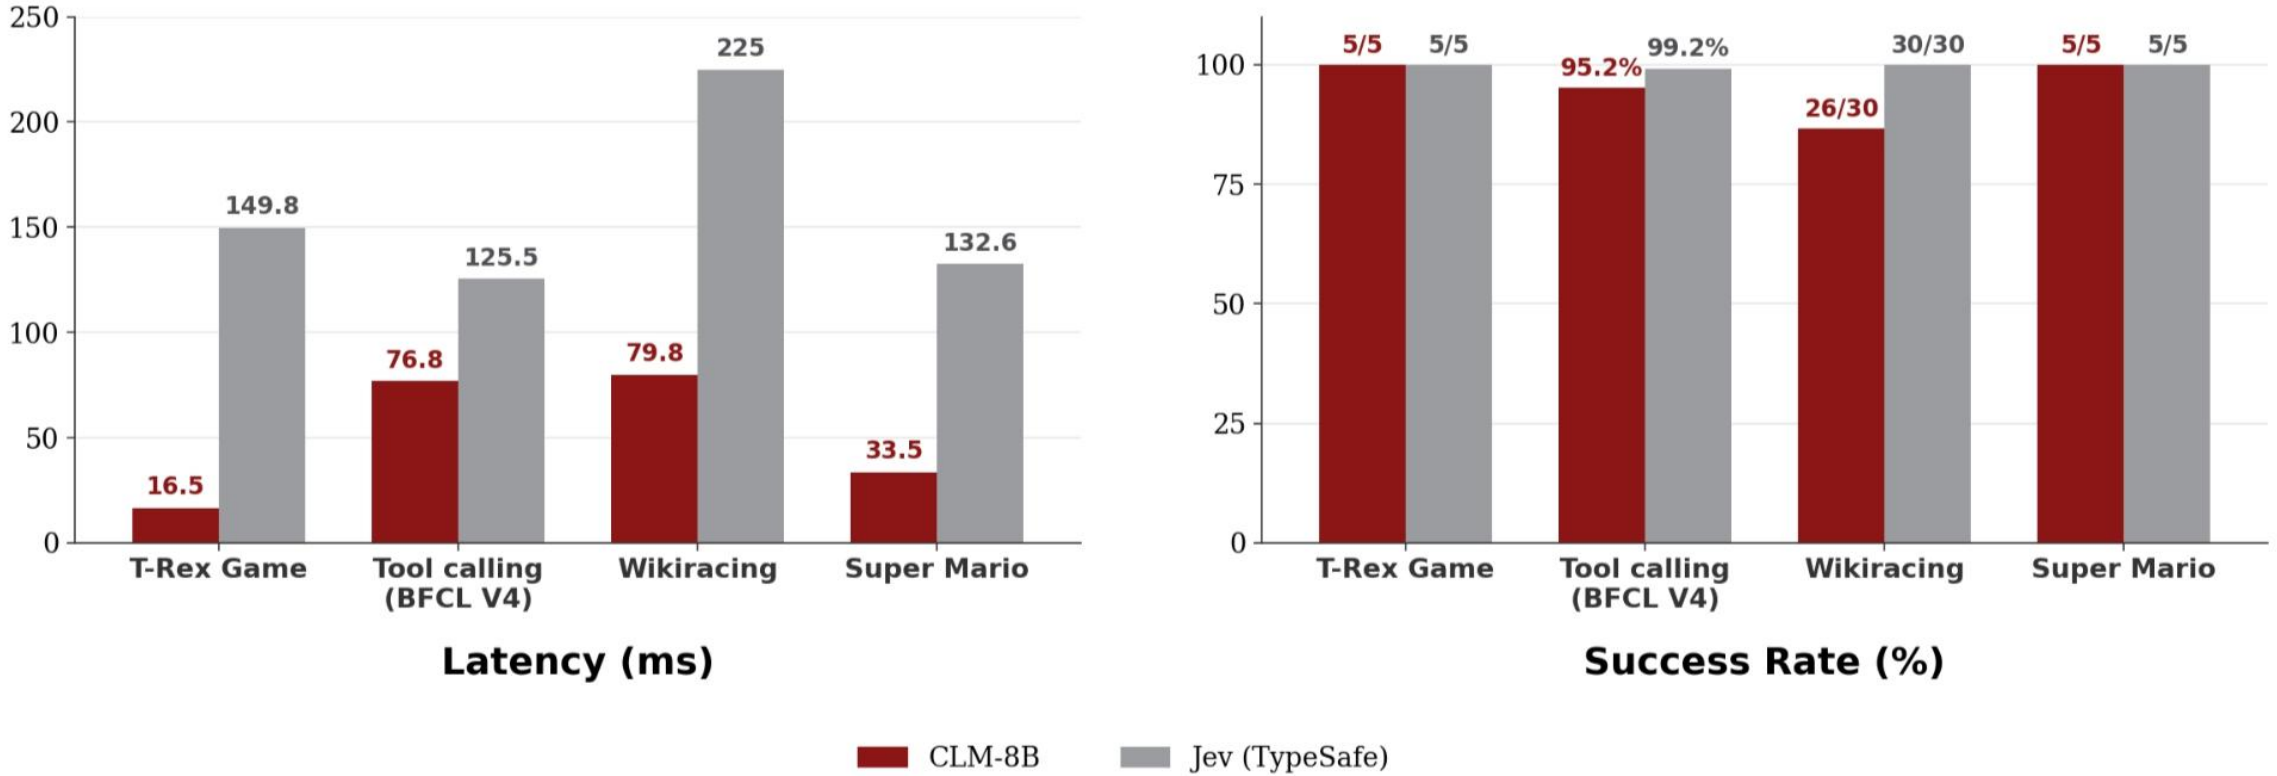
回答类型	问题	输出
Noul	是否紧急?	是：84.8%　　否：15.2%
Choice	交给哪个部门?	账单：98.8%　　技术：1.21%
Score	有多不满?	2.00 / 2（非常生气）

Score 等级：0 = 平静，1 = 不满，2 = 非常生气。

本例最高概率答案与 Jev 一致

CLM：能力与延迟评测

CLM 延迟更低；工具调用和 WikiRacing 成功率略低于 Jev。



左：决策延迟，越低越快。右：成功率，越高越好。

从模型接口，走向可执行的 Agent 循环

上一部分：判断如何输出

State 描述事实，候选定义问题。
Choice / Score / Noul 返回结构化结果。

→

接下来：判断如何落地

从网页、桌面和历史中构造状态。
选动作、交给程序执行，再校验反馈。

Agent 的三个决策位置

外部动作、内部记忆与时效约束分别决定不同的系统开销

动作执行

Browser Use + Desktop
从当前控件里选择动作，
缩短交互与反馈的循环。

上下文管理

fast-jev-compaction
判断哪些历史仍有用，
让长任务保留必要信息。

连续决策

jev-trader
在环境变化的节奏里，
持续选择并处理迟到。

Jev 的决策接口

给定状态和问题，返回受类型约束的判断

输入 / 输出	在 Agent 中的含义	示例
State	由代码组织的当前事实	可见控件、历史动作、目标
Choice	从明确的选项中选择	CLICK / SCROLL / DONE
Score	按定义好的等级评分	证据支持程度、任务优先级
Noul	返回“是”的概率	这个工具结果还需要保留吗?

高频决策的收益与代价

单步约加速 3.7 倍，但模型耗时与系统耗时不能混用

作者单样例对照	Jev + OCR	Opus 5 + 截图
单次模型决策成本	约 $0.0002	约 $0.032
模型调用耗时	0.13–0.38 s	5.2 s
完整单步耗时	约 1.5 s	约 5.5 s
模型外合计（差值粗估）	约 1.1 – 1.4 s	约 0.3 s

串行近似：T单步 = T感知 + T判断 + T执行 + T等待与校验

差值估计：模型外耗时 ≈ 完整单步耗时 − 模型调用耗时。

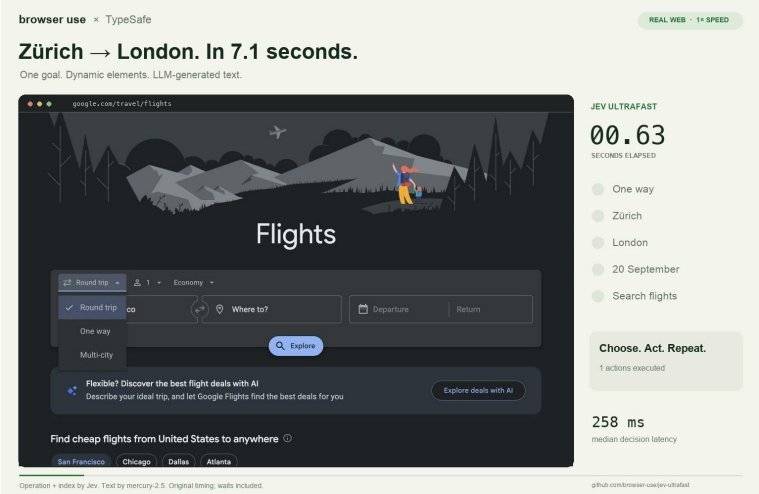
计时口径不同：Jev 的 OCR 在模型外，Opus 的视觉理解计入模型调用。

Agent 案例与比较维度

项目 / 作者	Jev 的应用	阅读重点
jev-ultrafast Browser Use	浏览器动作与目标选择	状态与动作解耦
typesafe-computer-use Aaron Levin	桌面操作与感知适配	感知路径与执行校验
fast-jev-compaction Tamara Tran	长任务的上下文保留	历史去留与信息保真
jev-trader Jarrod Watts	有时间预算的连续判断	时效、约束与回执

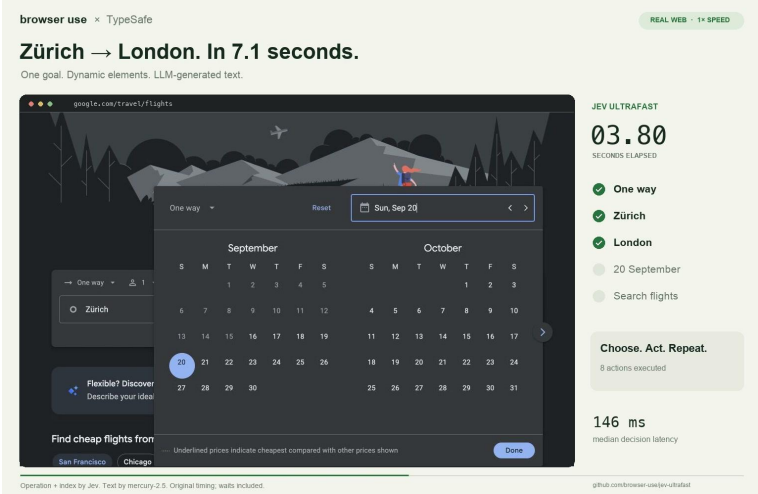
Browser Use：从输入条件到航班结果

目标：搜索 Zürich → London 的单程航班



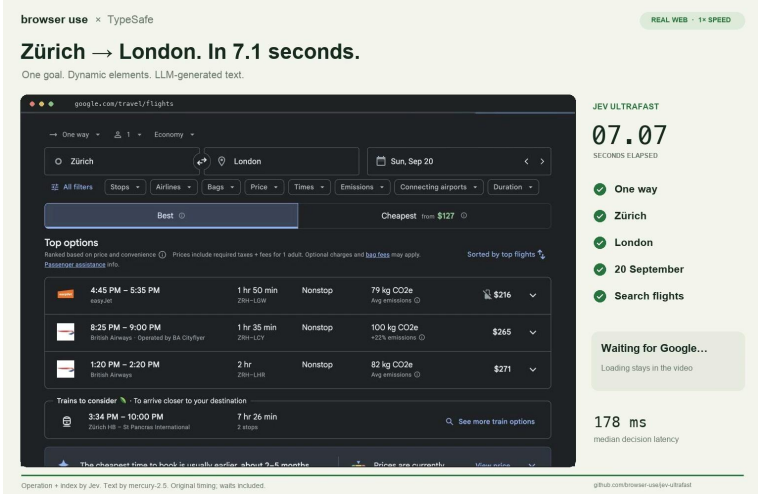
设定起点与终点

将页面控件整理成候选。



选择日期与控件

Jev 选操作；文本模型填内容。



返回并检查结果

程序核对路线、日期与结果。

作者单次演示耗时：7.073 秒。

动作拆解：把网页压缩为可执行的候选表

一次 Jev API 请求可提交多道选择题，并一次返回各题答案

State	可见文本、编号控件、当前值、目标与历史
Jev Question	例：同一请求提交三道选择题 ① 下一步操作？② 点击哪个控件？ ③ 输入哪个控件？三题共用页面状态
Choice	示例返回： 操作 CLICK，点击目标 [7]，输入目标 [3]
Action	按操作类型只使用匹配的目标答案。 先校验状态与遮挡，再点击 [7]。
Environment	重新读取页面，独立校验路线、日期和结果

适合在哪里

页面控件可以枚举；模型无需生成 selector 或坐标。

多道选择题，一次请求

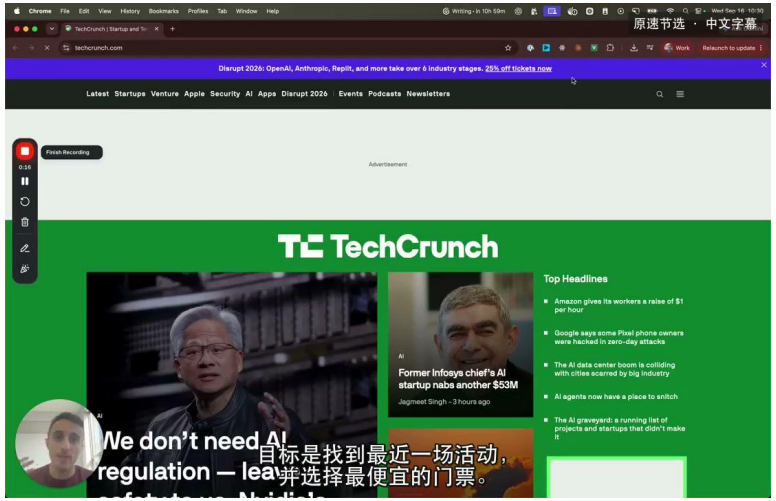
多道题打包提交，一次返回答案。
操作与目标一起选，省去二次请求。
输入内容仍交给文本模型生成。

当前限制与风险

网页内嵌子页面中的控件未被读取，因此无法选择。
模型判断“已完成”后，仍需核对实际结果。

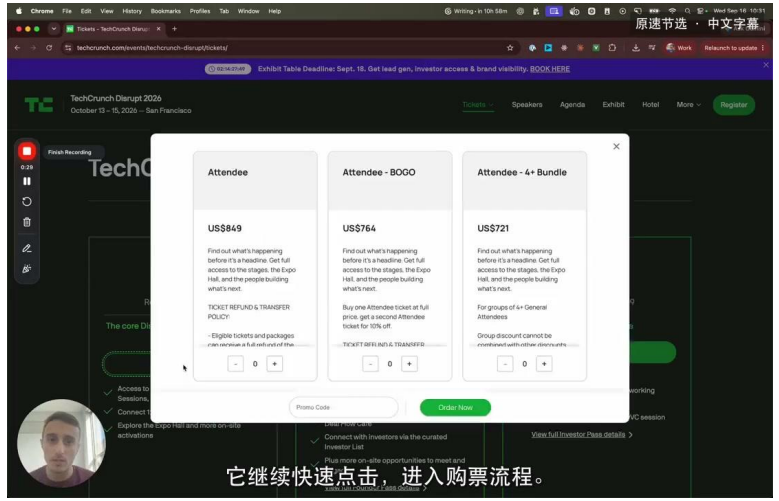
Computer Use：把屏幕变成可选目标

目标：进入 TechCrunch 活动中最便宜门票的结账页面



读取屏幕内容

OCR 与辅助功能提取文字和位置。



选择可执行控件

Jev 按目标选择编号，程序点击。



核对票种与价格

再次观察，确认下一步购买入口。

模型决策成本：约 $0.0002 / 次（作者单样例）。

屏幕截图先在本地提取信息，Jev 接收带编号的文字与控件列表

屏幕信息如何提取

Vision OCR 识别文字与边界框。
辅助功能接口读取控件名称、类型和位置。
程序合并重复结果，为候选项编号。

提交给 Jev 的状态

目标：进入活动购票页面。
state 包含应用、网址、焦点和操作历史。
每个候选项附上文字、类型与位置提示。

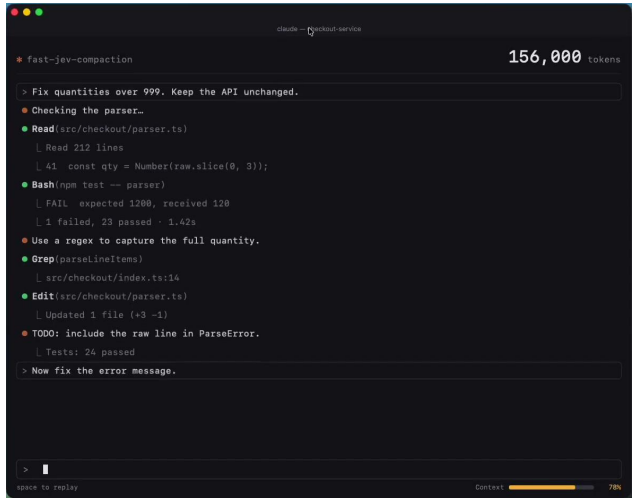
编号	屏幕文字	提交给 Jev 的候选描述	程序本地保留
6	Learn more	link 'Learn more' 位置 middle-right	控件引用与边界框
7	Buy tickets	button 'Buy tickets' 位置 middle-right	控件引用 框 [800，400，1000，460]
8	Subscribe	button 'Subscribe' 位置 top-right	控件引用与边界框

本轮 Jev 请求提交结构化状态。原始截图用于 OCR，精确坐标留在程序中。

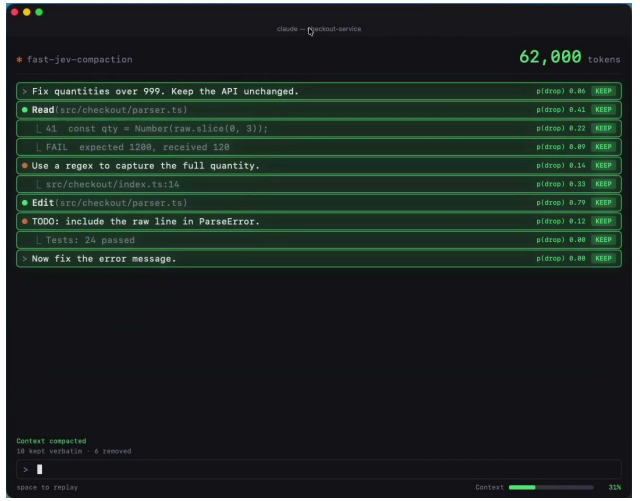
Jev 根据任务和候选描述选编号，代码负责把编号还原为可执行目标。

上下文管理：把历史去留变成判断

fast-jev-compaction：需要保留哪些工具调用与结果?







历史内容累积

长任务带来大量工具记录。

逐项标记去留

判断调用与完整结果是否仍有用。

保留必要内容

保留、截短或整对删除工具消息。

动画示意：156k → 62k 为预设数值。

上下文拆解：记忆管理也可以成为决策问题

分别判断“记得做过什么”和“保留完整结果”是否还有价值

State	任务与会话历史；工具输出在状态里变成短注
Jev Question	两个 Noul：保留这次调用？保留完整结果？
Decision	keepResult / keepCall 概率与阈值比较
Action	保留整对；保留调用并截短结果；或整对删除
Environment	重建消息供 Agent 继续；异常时回退内置摘要

适用条件

大量旧工具结果会过期，而文件路径、错误与约束需保真。

相比调用 LLM 摘要

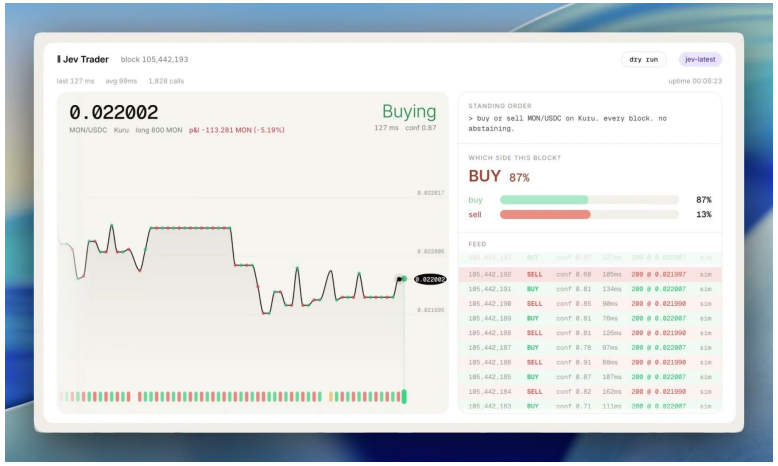
不重写保留内容；多条判断批量请求，普通文本原样保留。

当前限制与风险

若误删仍需使用的文件路径或错误信息，后续任务就可能重复查找，或遗漏尚未解决的问题。

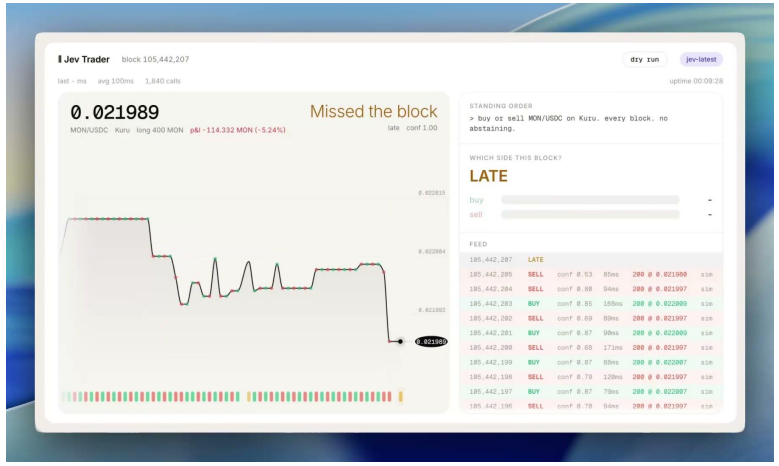
连续决策：状态时效也会决定结果

jev-trader：随新区块更新方向判断



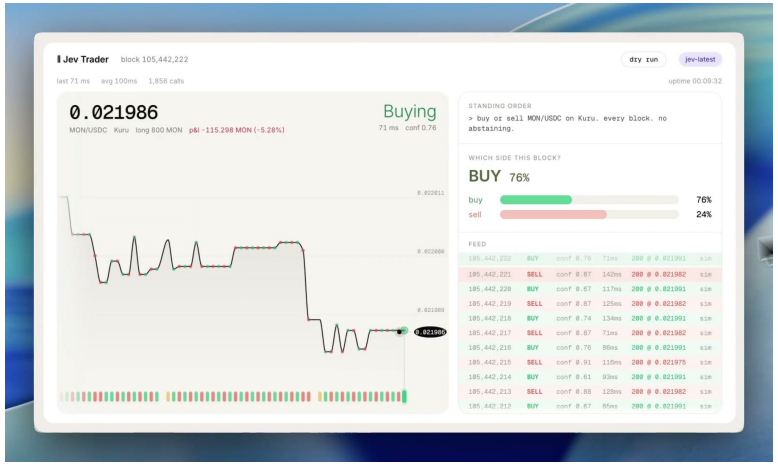
读取当前状态

由订单簿等信息构造状态。



识别迟到的判断

画面出现 LATE / Missed the block。



进入下一轮

代码处理方向、约束与执行回执。

区块间隔约 300 ms；演示模式为 dry-run / mock。

连续决策拆解：判断必须跟上状态的时效

选择足够快之后，时效、仓位限制与执行回执成为核心问题

State	订单簿、成交方向、价格变化与允许的方向
Jev Question	未来 horizonBlocks 后，价格更可能涨还是跌?
Choice	buy / sell + 概率；模型没有 hold 选项
Action	代码按仓位约束调整方向，撤旧单并提交挂单
Environment	异步读取回执与成交；忙碌时新块标记 late

适合在哪里

环境连续变化，决策对象小，调用必须进入固定时间预算。

相比逐步调用 LLM

不用生成交易脚本；模型选方向，代码确定价格、数量和执行。

总结：LLM、Jev 与 Code 的分工

低延迟和低成本，让 Agent 中的高频局部判断更值得交给模型

分工	适合承担的工作	何时触发
LLM：复杂推理	规划、异常解释、开放文本生成	新目标、复杂异常或需要写作
Jev：局部判断	控件选择、信息保留、路由与方向判断	观察刷新、候选明确
Code：执行约束	事实计算、保护规则、权限、时效与验证	每一次实际执行

Jev 的局限：输入、任务表达与判断可靠性

当前能力边界，以及我们可以补上的环节

局限	具体影响	可以研究什么
输入能力依版本而定	1.14 提供实验性图像与 Box 接口。 部分应用仍使用 OCR 或结构化状态。	研究状态编码与信息保留
任务需拆成局部判断	Choice 只选给定候选。 长程规划、代码或解释需其他模块。	研究候选构造与大模型协作
高置信度仍可能出错	置信度反映选项概率分布。 高置信度也需按任务验证。	用本领域数据校准执行门槛

从软件操作，走向有物理后果的行动

Agent 中的循环

界面状态 → 动作选择 → 执行与校验。
任务长了，还要管理记忆与时效。

→

机器人中的循环

空间观测 → 候选动作 → 控制与反馈。
执行开始受到接触、碰撞和时延影响。

具身系统中的决策位置

三类任务与比较对象

01	**空间认知与导航**	下一步往哪走，何时停止？ NavJev / Nav Arena
02	**动作预演与评估**	根据仿真预演，选择哪个候选动作？ jev-libero
03	**行为决策**	当前该执行什么动作？ EmbodiedJev / RoboJEV

方向选对与任务完成，是两个不同的判断。

NavJev 与 Nav Arena 都依赖更新后的观测；停止条件还需结合指令与实际位置。

路点选择

输入：路线指令、可走方向与语义记忆

输出：下一路点或离散运动方向

检查：正确方向是否进入候选

失败来源：状态遗漏、方向混淆、候选缺失

停止判断

输入：到达后的观测与目标条件

输出：继续移动或停止

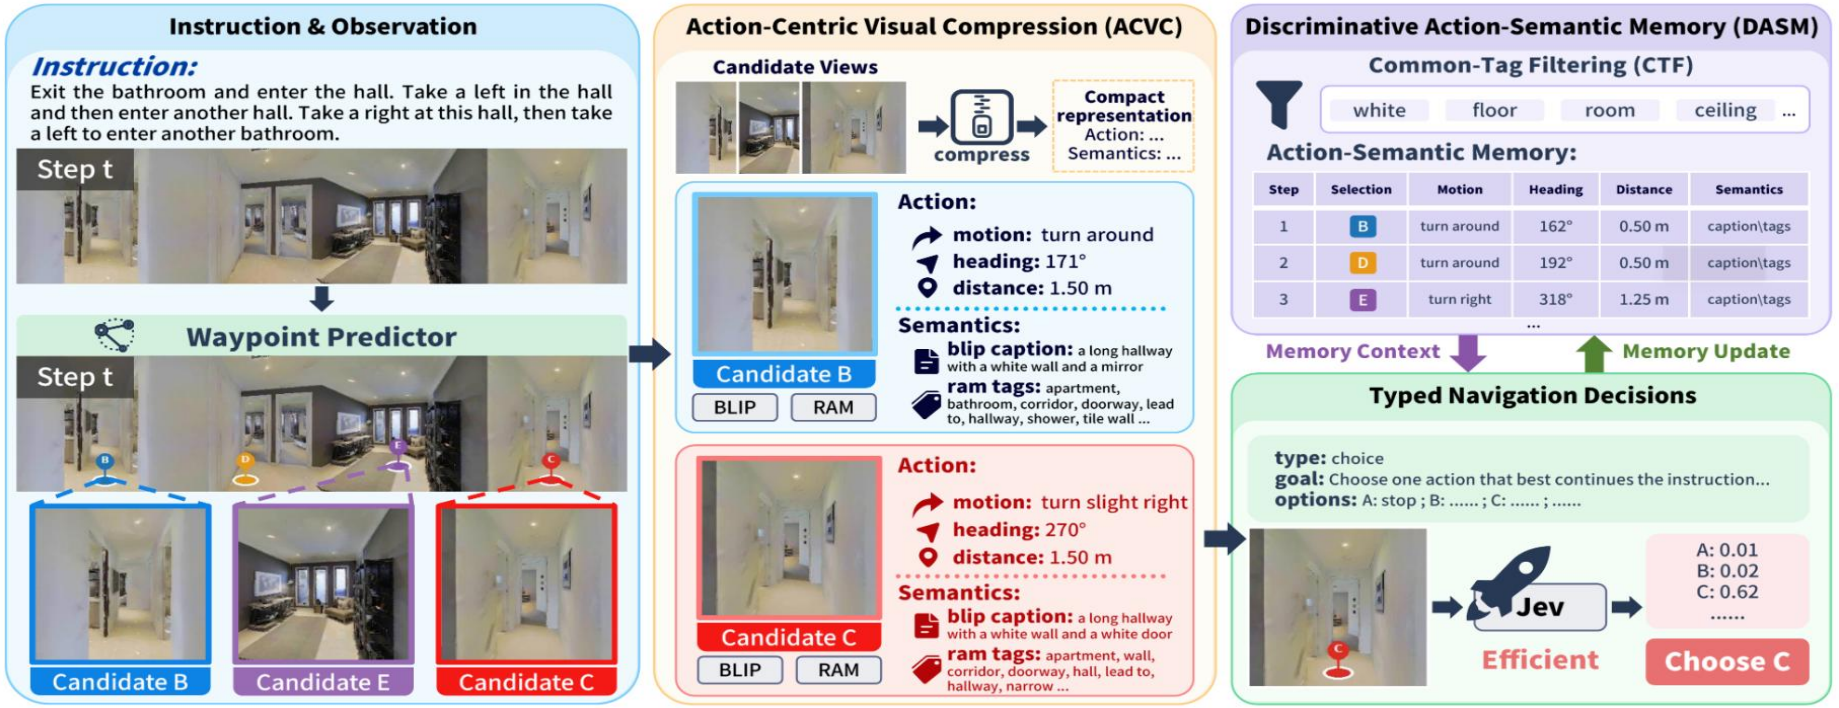
检查：位置与任务条件是否同时满足

失败来源：过早停止、越过目标、重复移动

NavJev：把视觉线索整理成导航选择

论文案例

任务：按路线指令行走，并在合适的位置停止



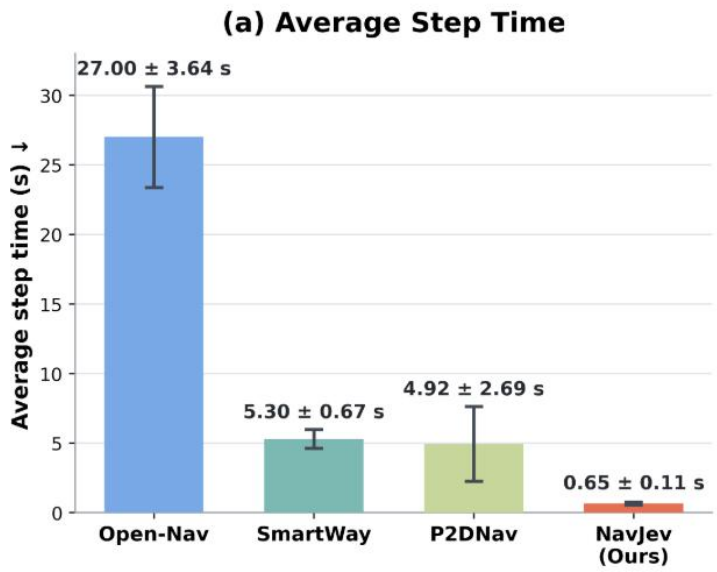
- 从全景图中找出可走路点，附上方向与场景描述
- 去掉重复标签，保留各方向差异与行动历史
- Jev 选择下一处路点或停止，执行后重新观察

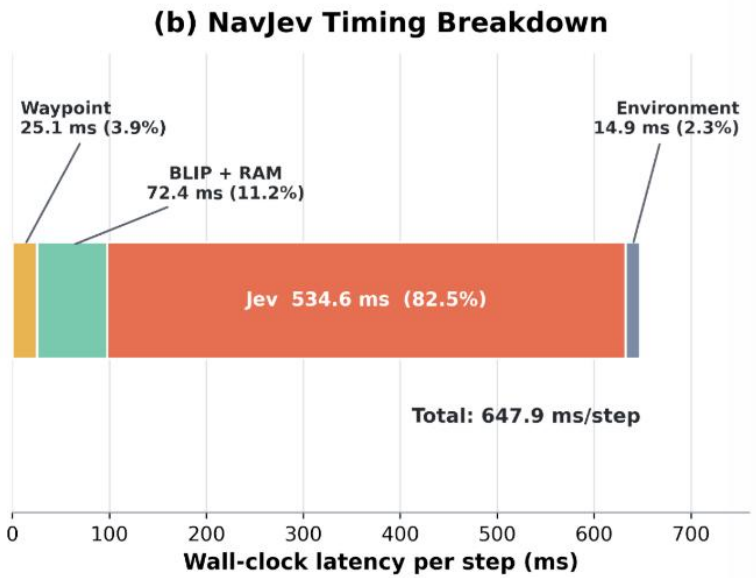
将视觉信息压缩为候选动作描述，保留能区分路线的语义记忆，再由 Jev 选择下一步动作

NavJev：把视觉线索整理成导航选择

论文案例

任务：按路线指令行走，并在合适的位置停止



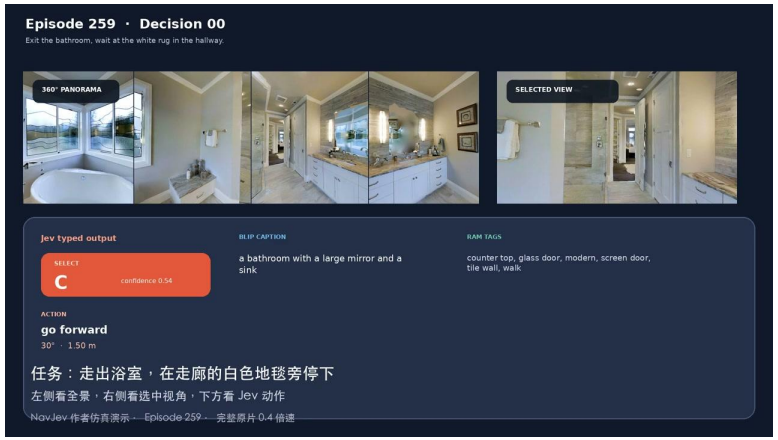


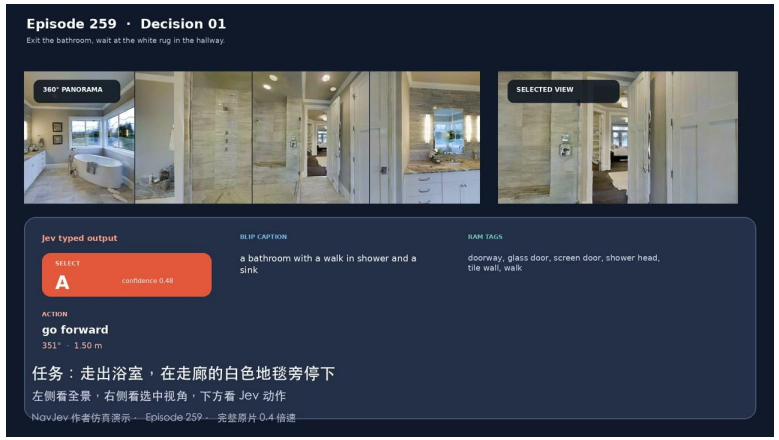
决策模型	成功率
GPT-4o	14%
Qwen3.8-Max	25%
Jev	27%

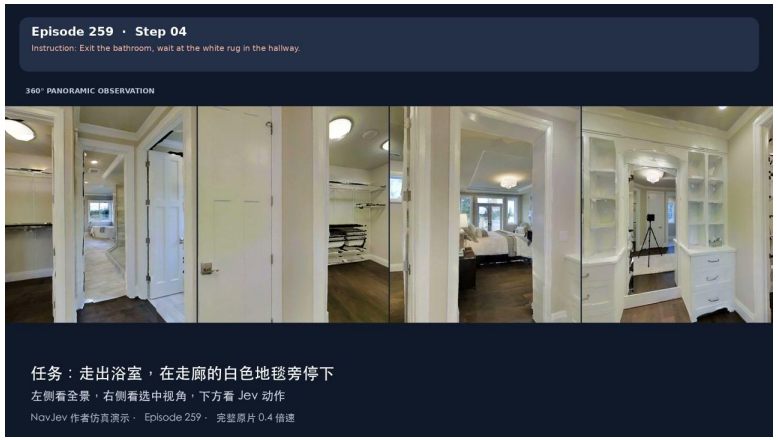
评测规模：100 个导航任务。

NavJev：从浴室走向走廊

指令：走出浴室，在走廊的白色地毯旁停下。







观察并比较路点

全景信息变成可选择的方向。

选择新的行进方向

选择后执行移动，再读新状态。

更新观测与停止条件

继续核对位置是否满足路线指令。

Can Jev Nav?：Jev 选择导航动作

项目案例

根据目标与空间状态，持续判断怎样移动、转向和停止

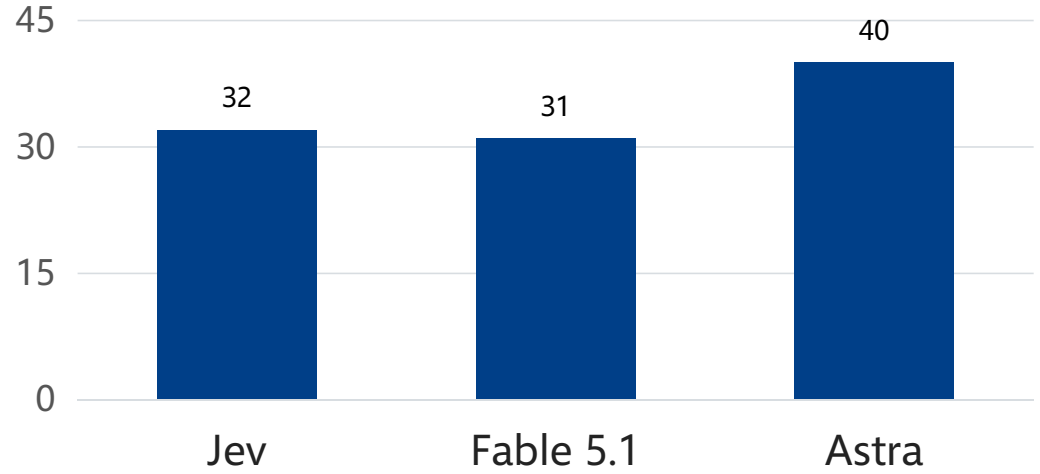
Jev 每轮作出六项判断

前后移动、左右平移、左右转向
是否停止、是否完成、目标是哪一个

判断怎样进入执行

程序把答案转换成速度命令
执行后更新空间状态，再交给 Jev

短程任务（小于 10 米）：到达数 / 45



每次运行成本（美元）

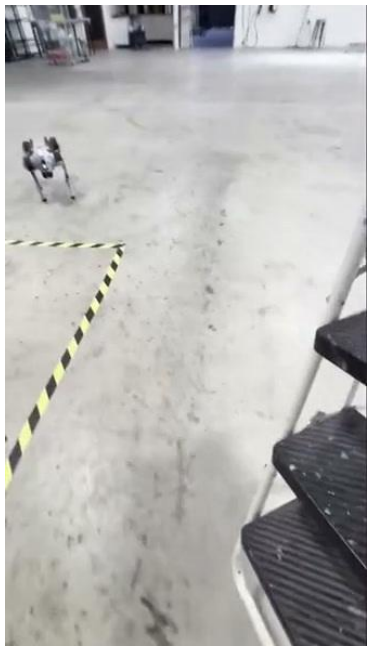
Jev 0.055　Fable 0.685　Astra 0.877

Nav Arena：真实运动中的重新观察

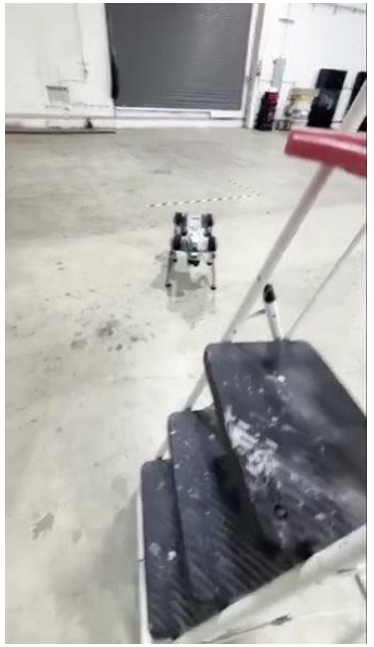
同一实机片段：接近目标时，持续更新移动、转向与停止判断。



远处观察



向目标接近



近距离校验

动作预演：预测、筛选与选择的职责

执行前比较动作后果，需要明确预测来自哪里。

jev-libero 使用已知物理仿真器：Jev 消费预演结果，参与分层动作选择。

01

预测后果

仿真器与测量程序

逐一预演 27 类基础动作。
记录接触、距离与任务进展。

预测误差：物理模型是否可信

→

02

筛选候选

任务程序

按接触约束与效果条件筛选。
把可行候选交给决策接口。

覆盖误差：有效动作是否被保留

→

03

分层选择

Jev

选择意图、类别与具体动作。
执行小步动作，再更新状态。

选择误差：是否选中有效动作

jev-libero：基于仿真预演的分层动作选择

项目案例

仿真器预测后果，程序筛选候选，Jev 分层选择下一步

环节	具体做法	负责模块
预演动作后果	27 种基础动作，逐一短时预演 计算接触、距离与任务进展	仿真器与测量程序
筛选可行候选	按配置的接触约束与任务效果条件 筛选可供 Jev 选择的动作	任务程序
分层选择动作	选择意图、接触 / 运动类别和具体动作 意图与类别按需更新	Jev
执行并反馈	执行选中的短动作片段 读取新状态，进入下一轮决策	控制与观测程序

jev-libero：从预演候选到实际动作

两个任务片段：推动微波炉门，以及抓取并搬移汤罐。



推动微波炉门

通过小步运动建立接触。



接近汤罐

比较接触与运动候选。



抓取并搬移

执行后读取新的物体状态。

长程操作：局部动作如何影响任务成功

把整条轨迹作为评测对象，定位第一次偏离目标的环节。

后续案例同时包含成功片段、超时记录与规则基线，避免只看单次成功演示。

接近目标	→ 建立接触	→ 持续操作	→ 验证完成
目标位姿与可达性	接触反馈与夹爪状态	物体运动与整臂碰撞	任务终止条件与超时

三个需要同时回答的问题

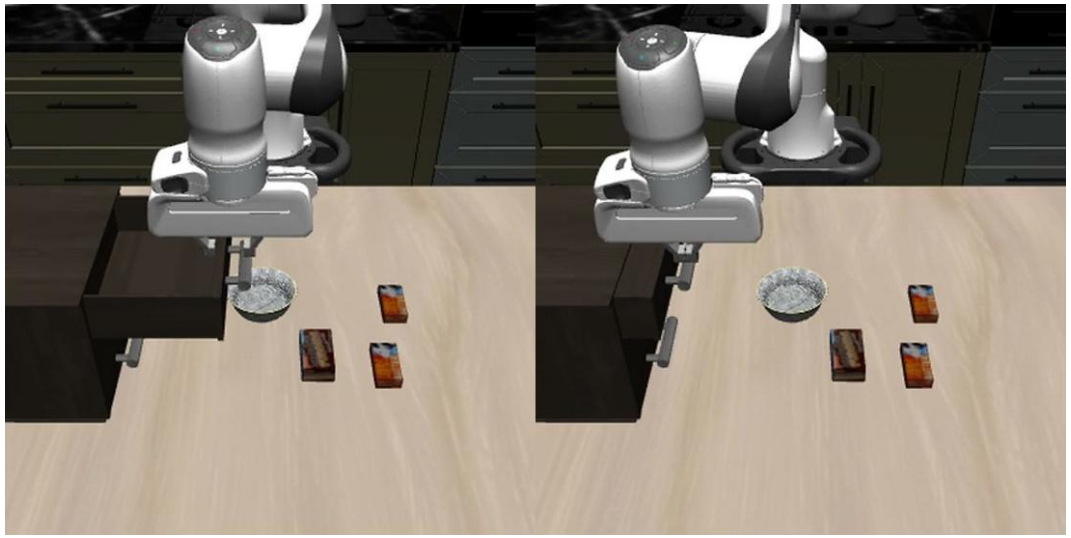
完成了多少：成功数 / 尝试数，并列保留强规则基线。

为什么失败：区分感知遗漏、候选受限、动作选择、控制误差与状态过期。

付出了什么：报告完整任务耗时、总调用费用，以及超时与恢复过程。

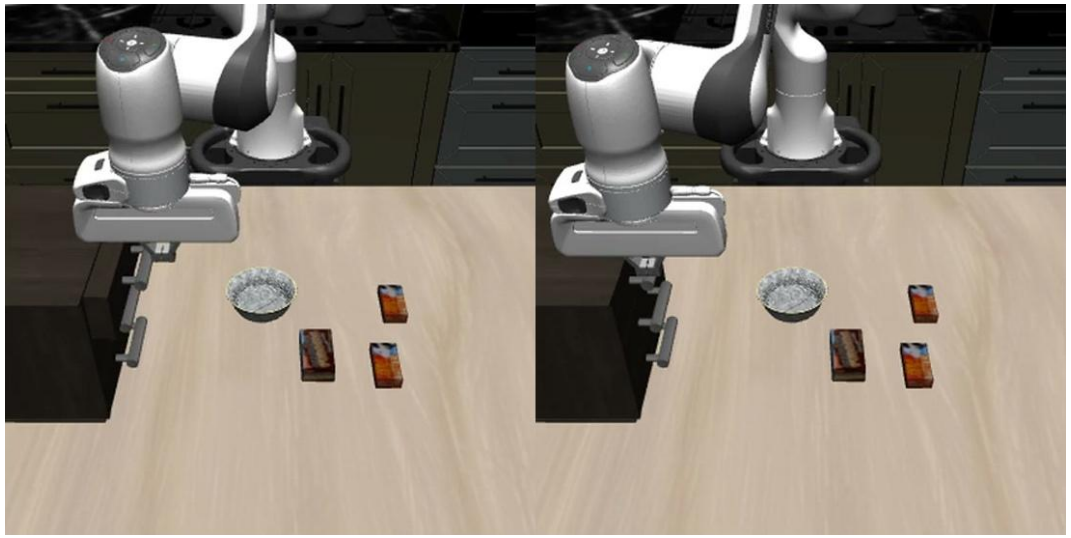
EmbodiedJev：比较局部动作选择方式

相同初态的关抽屉任务：每组图左侧为纯 GPT-6，右侧为 GPT-6 + Jev。



接近把手

比较两种局部动作策略的接近过程。



建立接触并推动

以实际反馈判断抽屉是否关闭。

EmbodiedJev：视觉规划与局部动作选择

项目案例

任务：根据视觉与状态反馈，关闭抽屉或微波炉门

视觉规划与局部动作分工

GPT-6：从图像与深度观测生成局部目标
Jev：根据目标误差与状态选择小步动作
控制程序：执行动作并返回新的观测



对照：使用相同视觉规划器
仅替换局部动作选择模块

输入：双相机 RGB-D 与本体反馈
输出：各轴运动方向与夹爪开合

实验结果：两项操作任务

任务 / 指标	纯 GPT-6	GPT-6 + Jev
关抽屉	完成	完成
耗时	约 610 秒	**约 320 秒**
估算费用	$2.15	**$0.39**
关微波炉门	完成	1200 秒 **未完成**

开发阶段运行记录

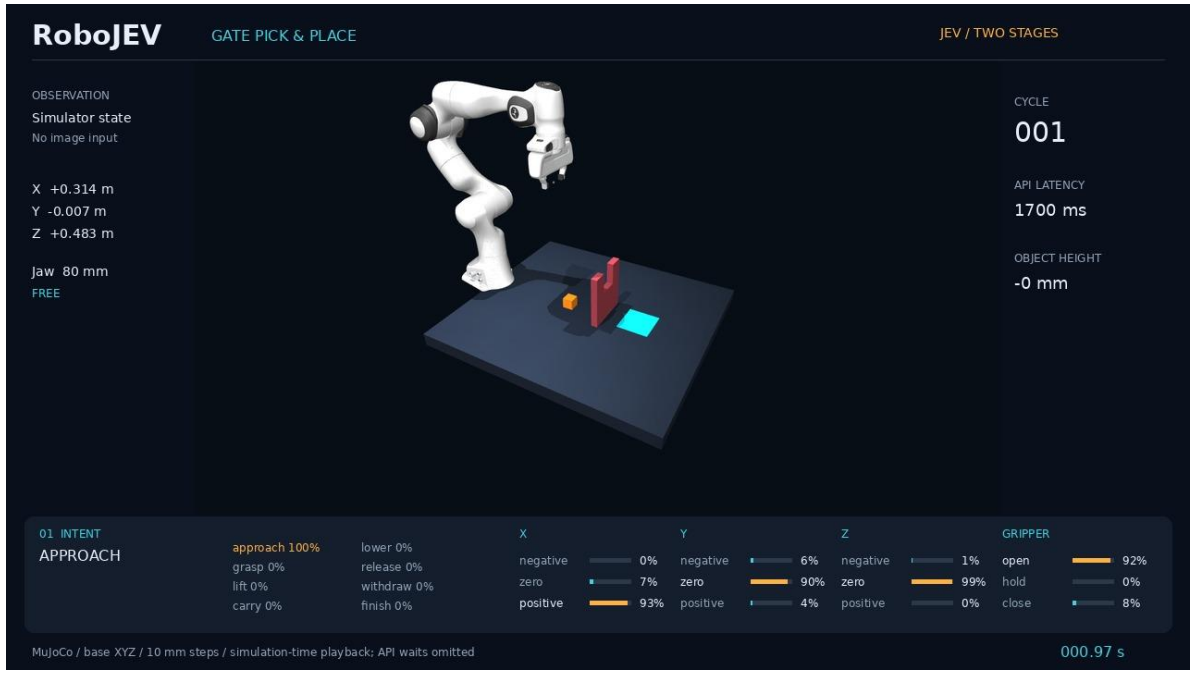
本次关抽屉任务耗时降低约 48%，而关闭微波炉门任务仍未完成

RoboJEV：局部方向与整臂碰撞

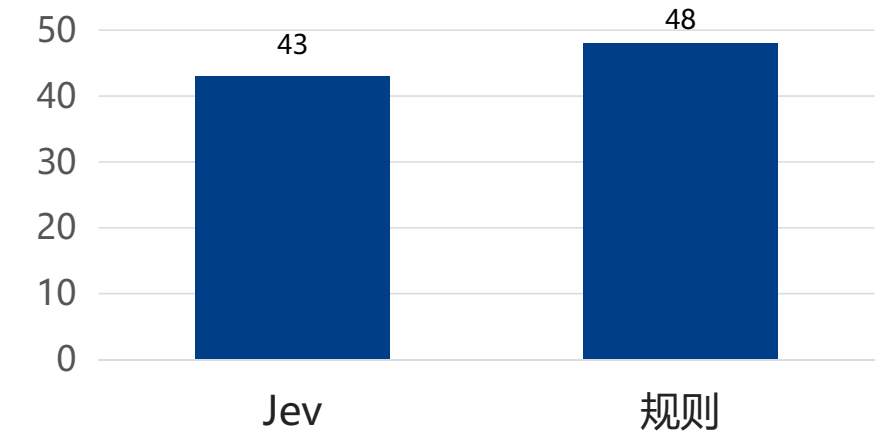
项目案例

先选接近、抓取等意图，再选 XYZ 方向和夹爪开合

读取物体位姿、接触与近期动作；程序把方向变成小步运动



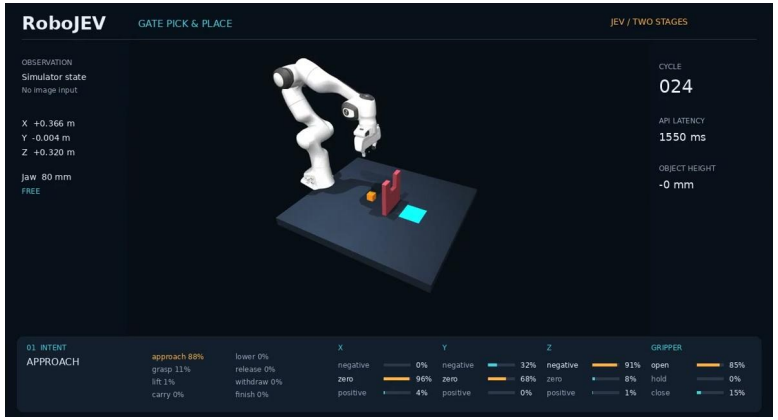
5 类任务，完整完成数 / 50

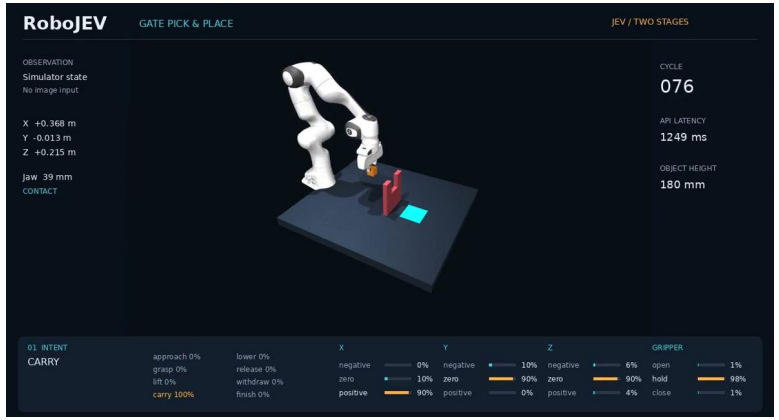


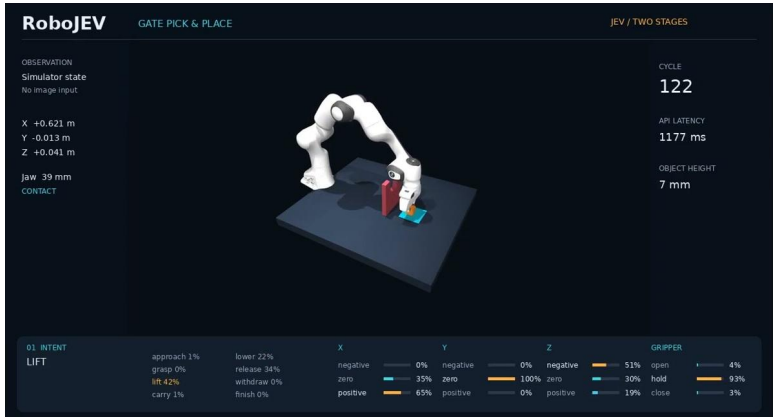
过门搬运：Jev 5/10，规则 8/10

RoboJEV：过门搬运的一条成功轨迹

按“接近与抓取 → 抬升过门 → 放到目标区”观察意图切换。







接近与抓取

局部方向与夹爪动作共同决定接触。

抬升并通过门框

需要同时考虑物体与整臂碰撞。

下降到目标区

根据高度与接触反馈继续调整。

过门搬运成功数：Jev 5/10，规则基线 8/10。

结论

从报告中的案例看，Jev 更适合处理选项明确、需要反复调用的局部判断。

模型机制	缺少正确选项且无法拒答时，高置信度也可能选错。候选设计应纳入评测。 概率读取、决策头等社区方法提供了实现思路，但不能据此推断 Jev 的内部架构。
Agent 应用	选控件、筛记忆等重复判断可以交给 Jev，规划和生成仍由 LLM 负责。 浏览器两组均使用 Jev，工程优化后仍有提速；评测应记录完整任务耗时。
具身实验	NavJev 接近 Qwen；操作实验有提速也有超时，RoboJEV 成功数低于规则。 还需固定观测、候选与控制器，比较完整任务的成功率、总耗时和费用。

参考资料

模型与接口

TypeSafe 文档	文档
Jev 基准评测（37 个数据集）	论文
OpenJev	代码
Visual Jev	论文
CLM	方法 / 代码

Agent 应用

Jev Ultrafast

typesafe-computer-use

fast-jev-compaction

jev-trader

具身智能

NavJev

视觉线索与导航选择 · arXiv:2609.34969

System One Navigation

Nav Arena 导航评测

jev-libero

仿真预演

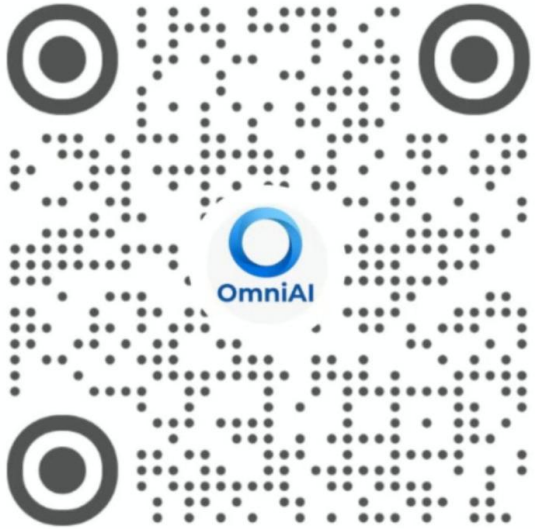
EmbodiedJev

局部动作选择

RoboJEV

完整任务评测

交流与资料



小红书 · OmniAI

扫码关注，获取研究进展与技术分享

开源资料：github.com/ZJU-OmniAI/Awesome-Jev